

# Tema 3: Segmentación

3.1. Introducción. Elementos y terminología

3.2. Segmentación de imágenes binarias

**3.3. Segmentación de imágenes en escala de gris**

3.4. Segmentación de imágenes en color

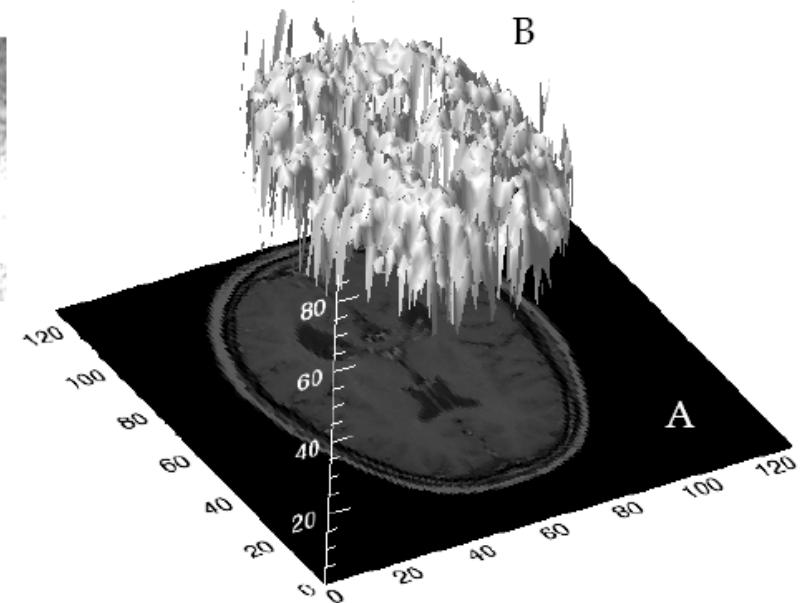
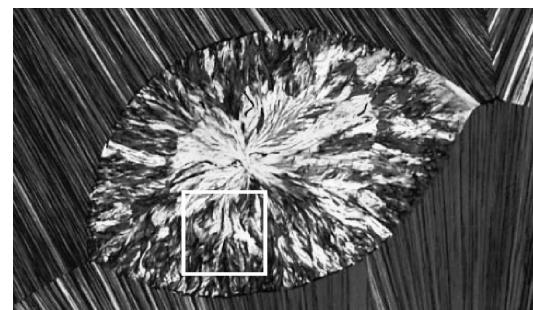
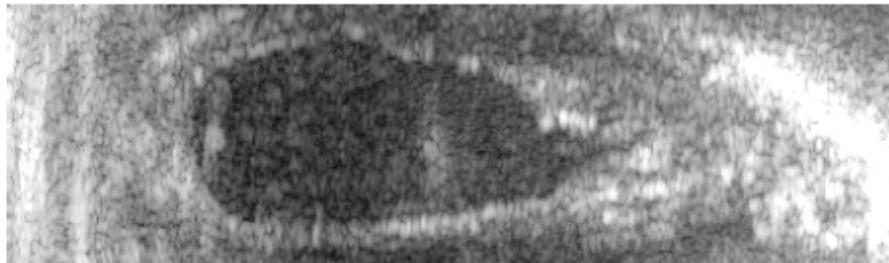
3.5. Segmentación basada en modelo. Transformada de Hough

3.6. Extracción de características

3.7. Técnicas basadas en aprendizaje estadístico. Aplicaciones

# Segmentación basada en textura

- ¿Qué es la textura? La textura es una propiedad innata a la naturaleza de toda superficie.



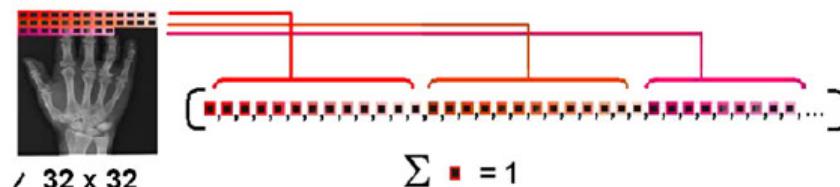
- No existe una definición formal de textura (ampliamente aceptada, simple y que carezca de ambigüedades). Glosario Estándar de Procesamiento Digital de Imágenes y Terminologías de Reconocimiento de Patrones (IEEE Standards Board, 1990): “la textura es un atributo que representa la distribución espacial de los niveles de gris de los píxeles en una región de la imagen”.

# ¿Cómo hacer la descripción de textura?

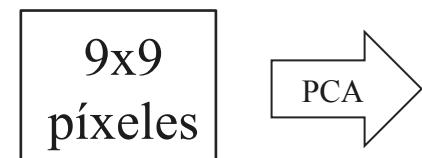
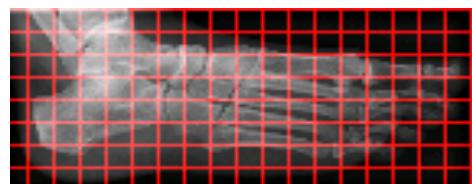
Se puede pasar de una imagen 2D o de un volumen 3D a un vector de números.



Un descriptor global puede ser la representación de los niveles de intensidad de los píxeles como un vector (previo escalado a un tamaño fijo).



En ocasiones, la caracterización global falla para capturar información relevante. Por ejemplo, en radiología médica, la información clínica se encuentra en regiones muy localizadas.



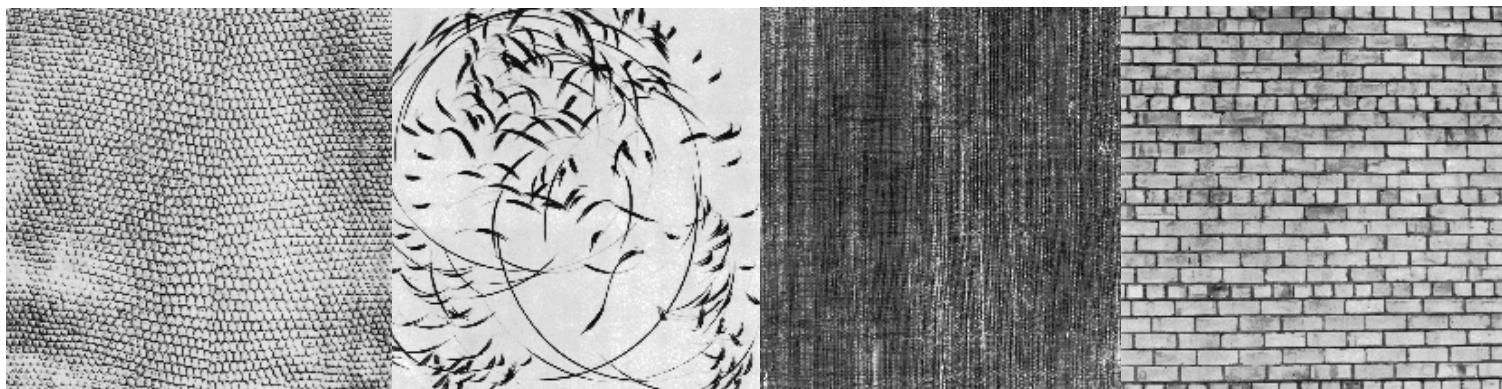
Por ejemplo,  
podemos utilizar  
como descriptores  
las 6 componentes  
con más energía



La textura queda caracterizada por relaciones entre píxeles, no por píxeles aislados. Es por ello que en el análisis de texturas se suelen utilizar operadores locales (filtros). La salida de los filtros se puede considerar como descriptores.

## Segmentación basada en textura

-Se pueden encontrar varios tipos de textura: con distintos intervalos de brillo, diferentes frecuencias espaciales y diferentes orientaciones. Aunque para el observador humano es más o menos fácil reconocer una textura y describirla en términos cualitativos, no lo es tanto su caracterización/discriminación cuantitativa.



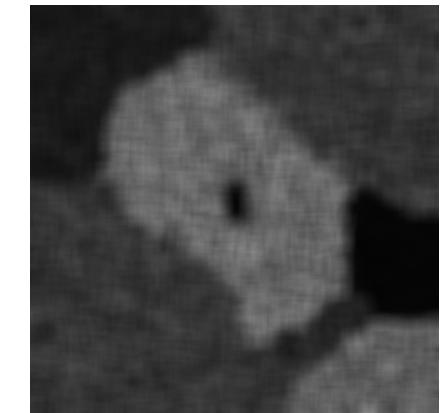
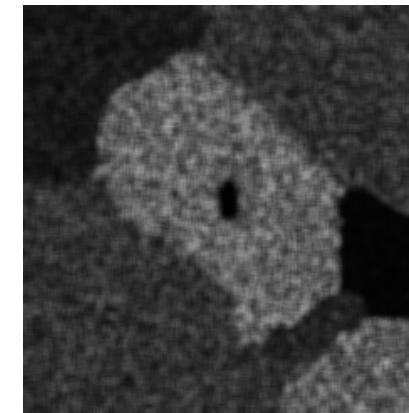
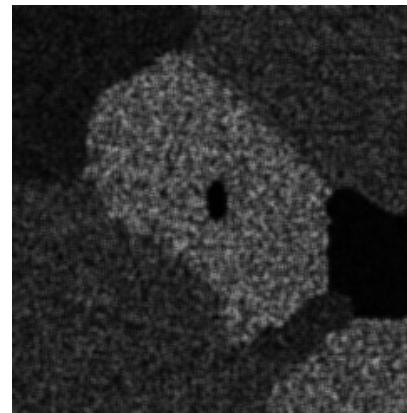
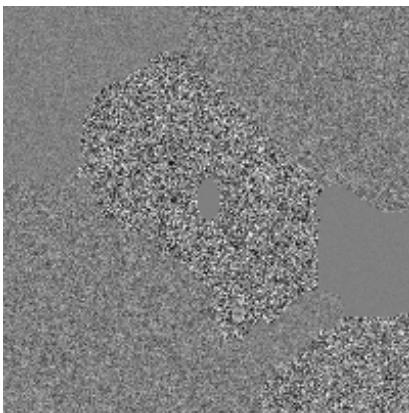
¿es adecuado aplicar una segmentación por nivel de gris?

- Como la textura queda caracterizada por relaciones entre píxeles, no por píxeles aislados, la textura contiene información acerca de la “estructura” de la superficie y su relación con el medio circundante.
- En el análisis de texturas se suelen utilizar operadores locales (filtros). La salida de estos filtros se puede considerar como característica (descriptor) para segmentar.

# Segmentación basada en textura

*Ejemplo: segmentación de texturas aplicando umbralización*

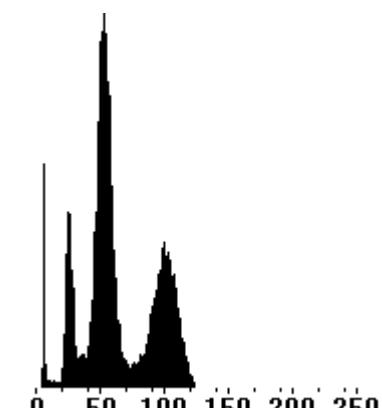
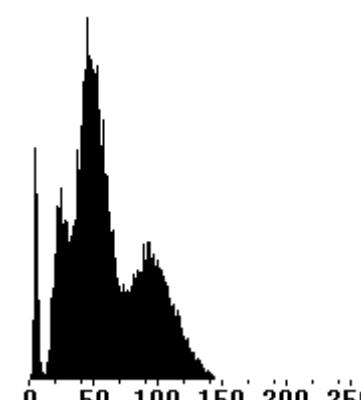
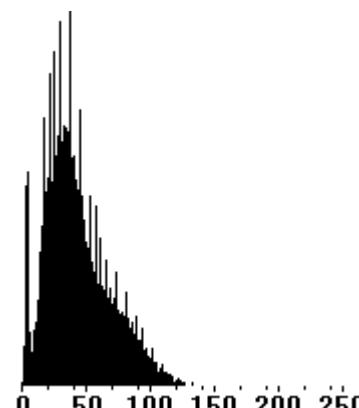
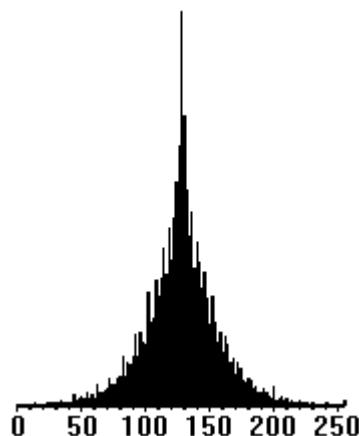
Dificultad para localizar de forma precisa una frontera de texturas: fluctuaciones aleatorias.



Filtro de varianza  
Máscara cuadrada 3x3

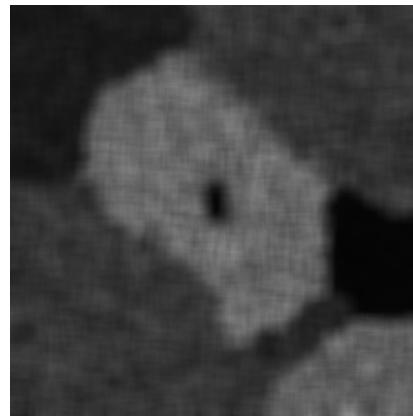
Filtro de varianza  
Máscara cuadrada 5x5

Filtro de varianza  
Máscara cuadrada 11x11

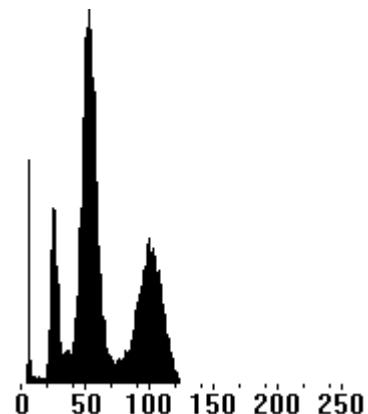


# Segmentación basada en textura

*Ejemplo: segmentación de texturas aplicando umbralización (cont.)*



Filtro de varianza  
Máscara cuadrada 11x11



Umbral 14



Umbral [15-35]



Umbral [38-72]



Umbral [75]

Dificultad para localizar de forma precisa fronteras entre texturas.

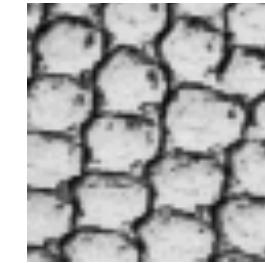
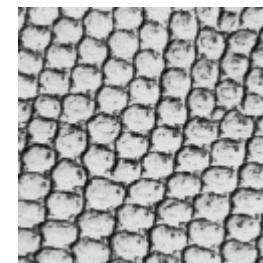
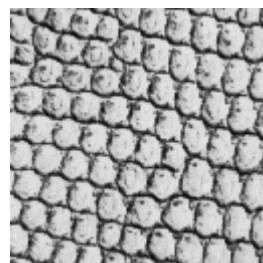
# Textura. Caracterización a través de descriptores

- Dependiendo de las propiedades de la textura a segmentar, el filtro deberá ser sensible a orientaciones, varianzas locales, periodicidades, ... Es por ello que, tradicionalmente, la caracterización de textura se realiza a través de **varios descriptores**.

Los descriptores de textura son parámetros que permiten caracterizar cuantitativamente la textura. Intuitivamente, estos descriptores proporcionan una medida de propiedades tales como suavidad, grosor y regularidad.



- Interesan descriptores invariantes ante rotaciones y escalado de la imagen.



# Caracterización a través de descriptores

-Para tener en cuenta simultáneamente varias propiedades, es usual que la caracterización de una región se realice a través de varios descriptores  $\Rightarrow$  vectores de características.

Es posible determinar los descriptores más informativos utilizando técnicas de selección de características.



Descripción

Adquisición de imagen

Preprocesado

Extracción de características

Selección de características

Clasificación/  
Segmentación

Imagen adquiridas con un  
dermoscopio y una cámara digital.

Características útiles para el diagnóstico del  
cáncer de piel:

- características morfológicas y de color
- características relacionadas con textura  
(contraste, energía, entropía,  
homogeneidad)
- características relacionadas con la  
dimensión fractal

Combinación de todas las características  
para mejorar las prestaciones.

# Principales enfoques para caracterizar la textura

- Los principales enfoques para describir la textura son: el enfoque estadístico, el estructural, el espectral y el de multi-resolución.

El enfoque **estadístico** facilita la caracterización de la textura en términos de suavidad, rugosidad, regularidad, granularidad, etc. Es el enfoque que se ha considerado más importante para el análisis de textura.

El enfoque **estructural** caracteriza las propiedades geométricas de los elementos de textura e intenta extraer la regla de ubicación de esos elementos.

Las técnicas **espectrales** se basan en la composición espectral en la imagen. Se hace uso del espectro de potencia de Fourier para detectar periodicidades globales identificando picos de energía. Los filtros de Gabor proporcionan descriptores que caracterizan la distribución de energía (en diferentes orientaciones) en la imagen.

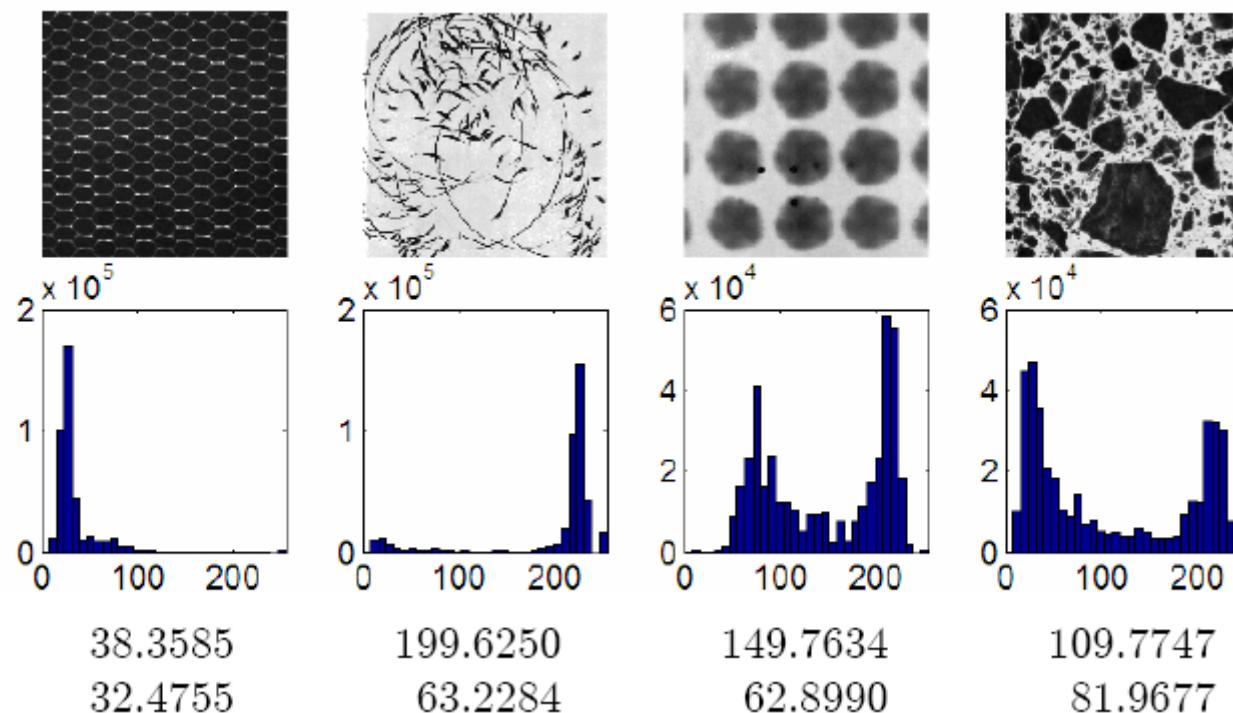
Las técnicas de **multiresolución** hacen uso de fractales y transformadas *wavelets* para estudiar el comportamiento de la textura a diferentes escalas.

# Descriptores basados en técnicas estadísticas

## - Técnicas estadísticas

Se apoyan principalmente en estadísticos de los niveles de gris de la imagen. Estos estadísticos pueden ser de Primer, Segundo o de Tercer orden. El orden del estadístico depende del número de píxeles considerados.

**Primer orden:** los descriptores de primer orden se calculan a partir de los niveles de gris originales. No tiene en cuenta las relaciones espaciales entre píxeles. Ejemplo: media, varianza, entropía, momentos, suavidad relativa, intensidad de contraste, etc.

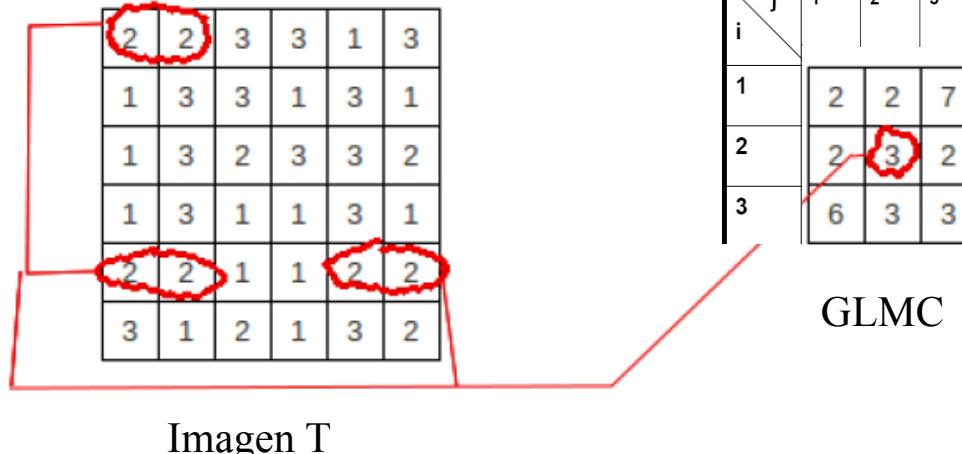


# Descriptores basados en técnicas estadísticas

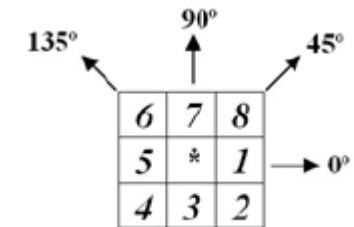
**Segundo Orden:** consideran la relación de co-ocurrencia entre grupos de dos píxeles de la imagen original situados a una determinada distancia y orientación.

Se definen sobre las matrices de co-ocurrencia 2D (matrices de dependencia espacial o **GLCM**, *gray-level co-occurrence matrix*) [Haralick, 1973]. Dada una imagen de textura T, una matriz de co-ocurrencia P se define en base a dos parámetros: d – distancia (medida en píxeles) y  $\phi$  – orientación (típicamente:  $0^\circ$ ,  $45^\circ$ ,  $90^\circ$  y  $135^\circ$ ).

Consideremos  $L=3$  niveles en la imagen de textura T. La matriz de co-ocurrencia (para  $d=1$ ,  $\phi=0^\circ$ ) es una matriz  $L \times L$  independiente del tamaño de la imagen, sólo depende del número de niveles de cuantificación L utilizados.



A partir de cada matriz de co-ocurrencia GLMC se derivan una serie de descriptores.



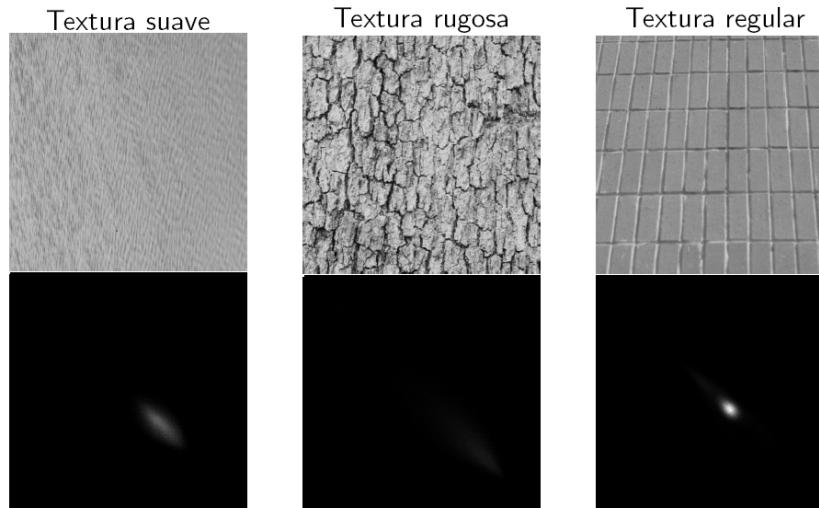
Para  $d=1$ ,  $\phi=0^\circ$ ,  $GLMC(i,j)$  indica el número de pares de píxeles contiguos (porque  $d=1$  píxel) en la dirección horizontal (porque  $\phi=0^\circ$ ) con intensidades  $i,j$  en T.

¿Qué sucede si la imagen T tiene ruido? Los patrones se “rompen”. Una solución es cuantificar los niveles de intensidad en intervalos que “absorban” las variaciones aleatorias de los niveles de intensidad.

# Descriptores basados en técnicas estadísticas

La matriz GLCM no puede utilizarse directamente para comparar dos texturas  $\Rightarrow$  se **normaliza** para que sea invariante al tamaño de la imagen: primero se convierte en simétrica (sumándole su transpuesta); seguidamente se expresa como una función de probabilidad, asignando a cada celda el valor correspondiente a la frecuencia de aparición.

Para cuantificar el “contenido” de la matriz de co-ocurrencia normalizada se pueden extraer descriptores que permitan caracterizar las texturas de manera más compacta.



Entropía, energía, contraste, homogeneidad, máxima probabilidad, correlación, momento de diferencia de orden  $k$ , momento inverso de diferencia de orden  $k$ , directividad, tendencia de cluster, ...

Textura	Max.	Corr.	Contr.	Unif.	Homog.	Ent.
Suave	0.0039	0.1348	0.0016	0.0007	0.2113	10.9143
Rugosa	0.0039	0.3471	0.0095	0.0001	0.1364	13.5796
Regular	0.0045	0.1129	0.0012	0.0015	0.2523	10.5032

# Descriptores basados en técnicas estadísticas

**Tercer orden (y superiores):** se consideran las relaciones entre 3 o más píxeles. Requieren mucho tiempo de cómputo y su resultado es de difícil interpretación.

Galloway propuso utilizar la **Matriz de secuencias de longitud de niveles de gris** (GLRL: *Grey-Level Run Length*) y extraer a partir de ella descriptores que permitan caracterizar la textura.

La matriz GLRL se define para una determinada orientación. Sus elementos indican el número de secuencias de niveles de gris de varias longitudes.

Una secuencia (*run*) de nivel de gris es un conjunto de píxeles linealmente adyacentes que tienen el mismo nivel de intensidad y están situados en una determinada orientación.

La componente **GLRL( $i, j$ )** indica el número de series con píxeles de nivel de intensidad  $i$  y longitud de la serie  $j$  en esa orientación.

1 1 2 2 1 1
3 3 1 1 2 2
1 1 2 3 1 1
3 1 2 2 1 1
1 1 3 2 2 2
2 3 1 1 2 2

0 °

j \ i	1	2	3	4	5	6
1	1	8	0	0	0	0
2	2	4	1	0	0	0
3	4	1	0	0	0	0

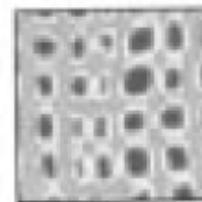
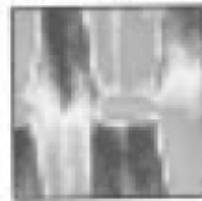
$i$ : nivel de intensidad (número de filas)

$j$ : longitud de la serie o *run length* (número de columnas)

¿Cómo podríamos diferenciar texturas finas de texturas “coarse”?

# Descriptores basados en técnicas estadísticas

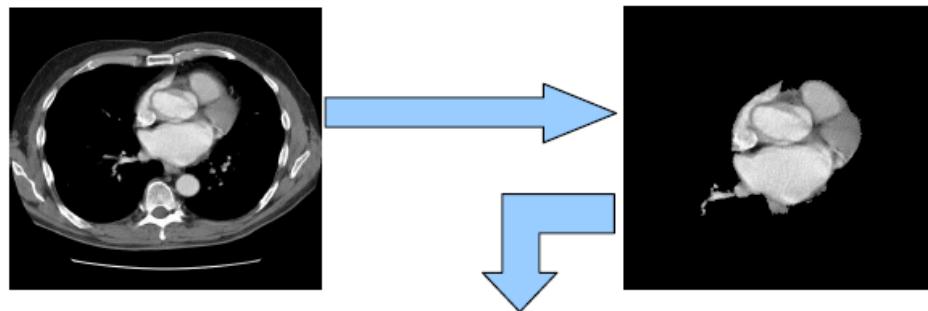
Composición de matrices GLRL para imágenes de tamaño 32 x32 píxeles con 32 niveles de intensidad.



# Descriptores basados en técnicas estadísticas

Al igual que con la matriz de co-ocurrencia, a partir de la matriz GLRL se definen varias medidas estadísticas (descriptores) para capturar las propiedades de textura.

Short Run Emphasis (SRE); Long Run Emphasis (LRE); High Gray-level Run Emphasis (HGRE); Low Gray-level Run Emphasis (LGRE); Short Run Low Gray-Level Emphasis (SRLGE); Short Run High Gray-Level Emphasis (SRHGE); Long Run Low Gray-Level Emphasis (LRLGE); Gray-Level Non-uniformity (GLNU); Run Length Non-uniformity (RLNU); Run Percentage (RPC).



*Slice de tomografía de pecho y abdomen*

Valores promediados en las 4 orientaciones.

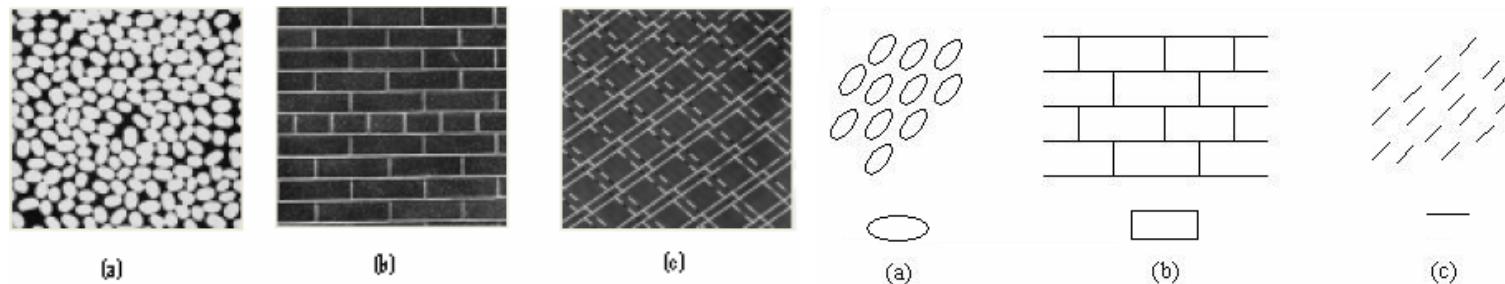
En la práctica, previo a la obtención de la matriz GLRL, las imágenes se cuantifican en un número fijo de niveles de intensidad

SRE	LRE	LGRE	HGRE	SRLGE	
0.7946625	1.9866925	0.0049275	209.80237	0.00399	
SRHGE	LRHGE	LRLGE	GLNU	RLNU	RPC
163.619125	434.95482	0.0093575	218.6210575	584.8621275	0.769425

# Descriptores basados en técnicas estructurales

## - Técnicas estructurales

Se basan en **patrones primitivos** o texel (del inglés “*texture element*”) y en una descripción del modo en el que se agrupan para formar la textura en sí.



Ejemplos de texturas, sus correspondientes texels (celdas básicas) y patrones de repetición.

Tras identificar los texels se puede extraer la regla de colocación (o descripción relacional) que describa la textura (para formar estructuras más complejas).

Estas técnicas son satisfactorias para analizar texturas muy regulares.

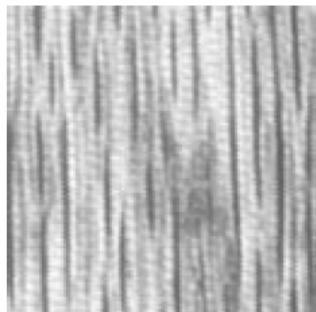
Aunque proporcionan una buena descripción simbólica de la imagen, estas técnicas son más adecuadas para la síntesis de una imagen que para su análisis.

# Descriptores basados en técnicas espectrales

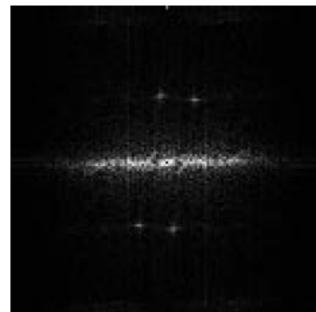
## - Técnicas espectrales

Consideran un modelo de imagen como señal bidimensional, de la cual se puede extraer el espectro de frecuencia espacial.

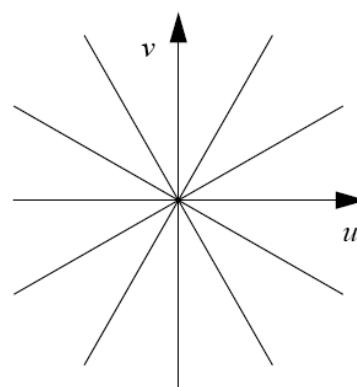
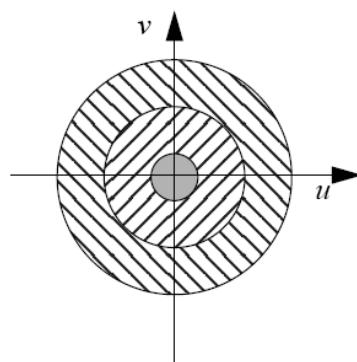
*Transformada de Fourier:* global



*Imagen en el dominio espacial*



*Espectro de potencia*



El espectro de potencia está especialmente indicado para caracterizar **patrones bidimensionales periódicos (o casi periódicos)** de una imagen, ya que estos patrones de textura son fácilmente distinguibles como **altas concentraciones de energía** en el espectro.

El espectro de potencia proporciona información sobre:

- la periodicidad de la textura: potencia media utilizando filtros en anillo (*ring*)
- la direccionalidad de la textura: potencia media utilizando filtros sectoriales (*wedge*)

# Descriptores basados en técnicas espectrales

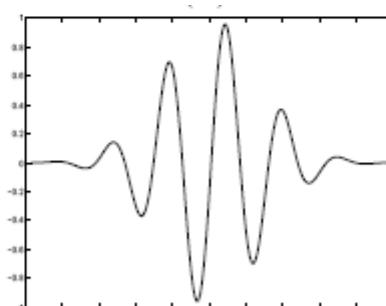
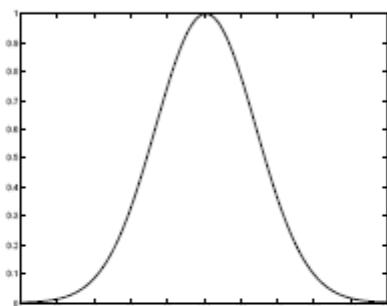
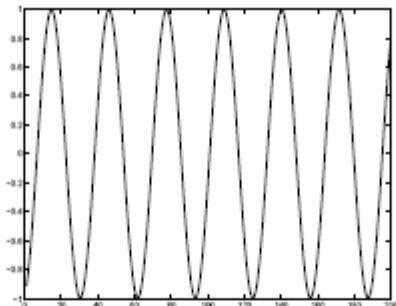
Los coeficientes de la TF dependen de la imagen completa  $\Rightarrow$  Inconveniente: mezcla las **variaciones espaciales** de diferentes partes de la imagen.



La TF no puede recoger la información espacial de esta figura, donde las líneas se vuelven más anchas hacia la derecha de la imagen.

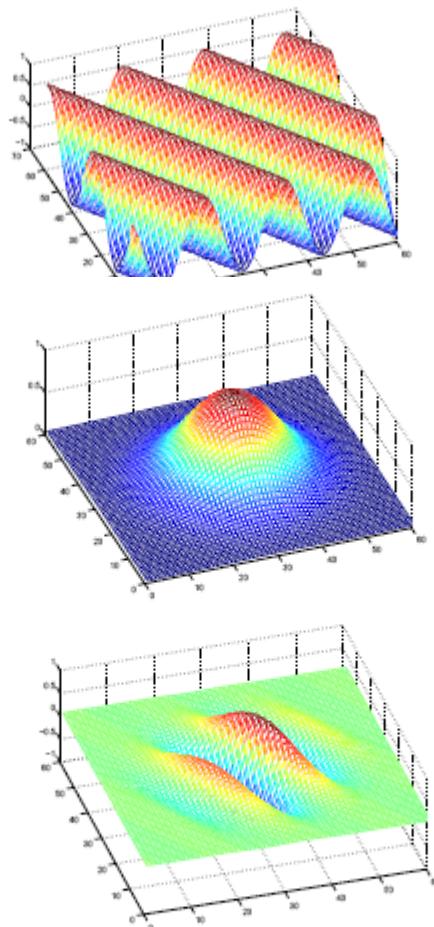
## Filtros de Gabor

Los filtros de Gabor 1-D fueron propuestos por Dennis Gabor en 1946. El Filtro de Gabor se obtiene modulando una sinusoida con una Gausiana  $\Rightarrow$  de esta manera el filtro responde a una determinada frecuencia, pero sólo en una parte localizada de la señal.



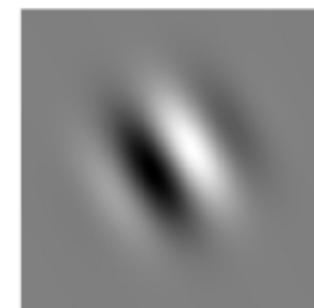
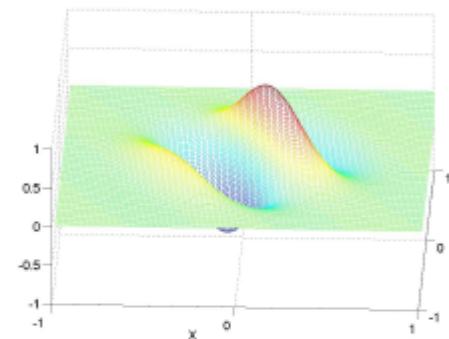
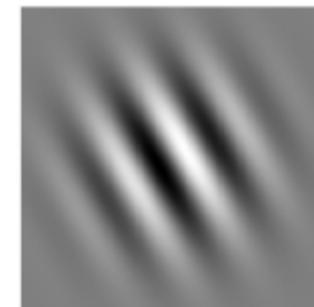
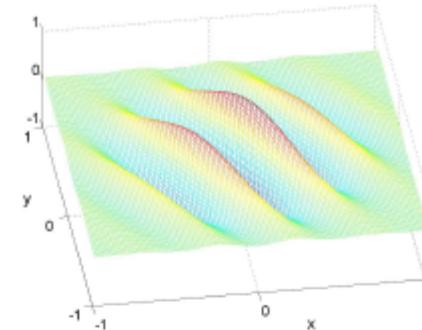
# Descriptores basados en técnicas espectrales

En los años 80, Daugman extendió el Filtro de Gabor a 2-D.



$$f(x, y, \omega, \theta, \sigma_x, \sigma_y) = \frac{1}{2\pi\sigma_x\sigma_y} \exp\left[\frac{-1}{2}\left(\left(\frac{x}{\sigma_x}\right)^2 + \left(\frac{y}{\sigma_y}\right)^2\right) + j\omega(x \cos \theta + y \sin \theta)\right]$$

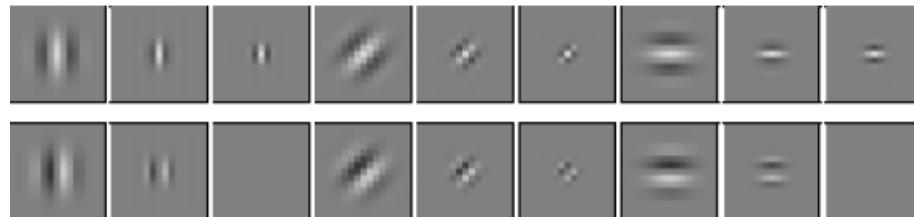
La respuesta del Filtro de Gabor proporciona un valor alto en regiones de la imagen donde existen componentes que localmente tienen una determinada frecuencia y orientación  $\Rightarrow$  se pueden utilizar para analizar cambios de frecuencia localizados en el espacio.



# Descriptores basados en técnicas espectrales

Bovik propuso a principios de los años 90 aplicar filtros Gabor multi-canal (selectivos a diferentes escalas, frecuencias y orientaciones) para extraer características de textura.

Banco de filtros de Gabor en función de la escala y la orientación.



## - Técnicas multiresolución

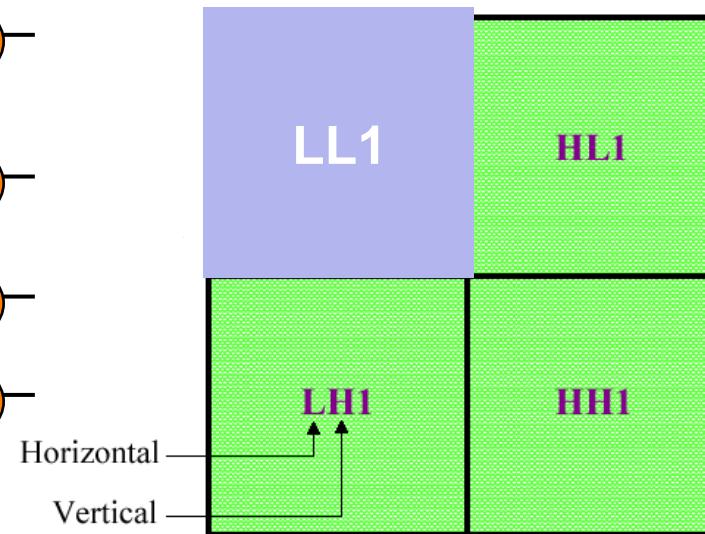
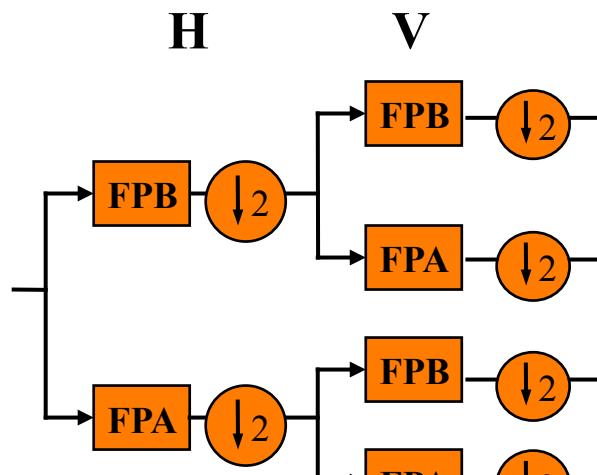
La Transformada Wavelet (*WT-Wavelet Transform*) permite realizar el análisis multiresolución (a distintas escalas) utilizando funciones base locales (duración espacial limitada). La resolución es una medida de la “cantidad de detalle” de una imagen.

La imagen original se descompone en un conjunto de imágenes con distinta información de detalle (varias resoluciones) aplicando repetidamente filtros paso bajo (aproximación) y paso alto (detalles) a las filas y columnas de una imagen. Tras cada etapa de filtrado se realiza un sub-muestreo para que el número total de píxeles no se modifique.

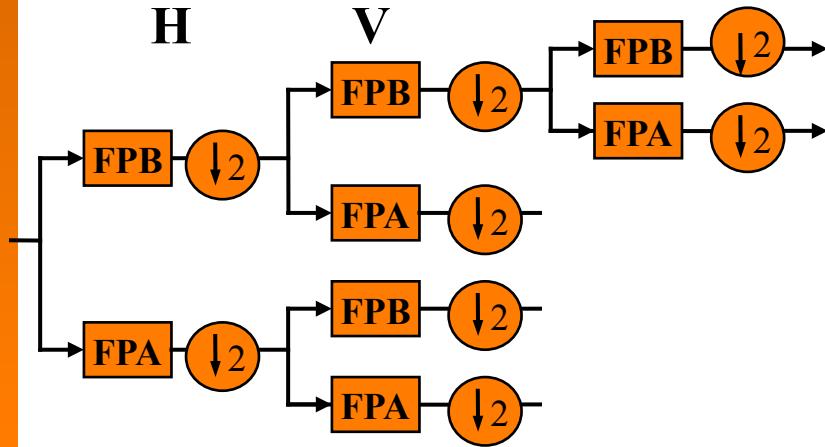
# Descriptores basados en técnicas multiresolución

Los cuatro filtrados realizados, denominados LL, LH, HL y HH suponen un nivel de transformada sub-banda y se corresponde con cada una de las subimágenes obtenidas  $\Rightarrow$  en cada nivel se obtienen 4 imágenes (sub-bandas).

El proceso de filtrado se repite en la sub-banda LL.



# Descriptores basados en técnicas multiresolución

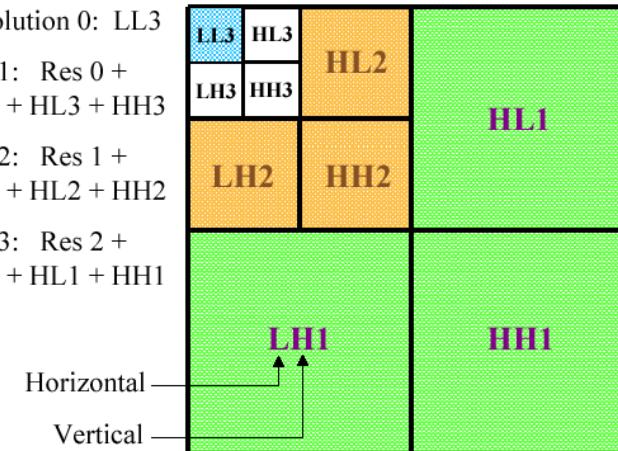


Resolution 0: LL3

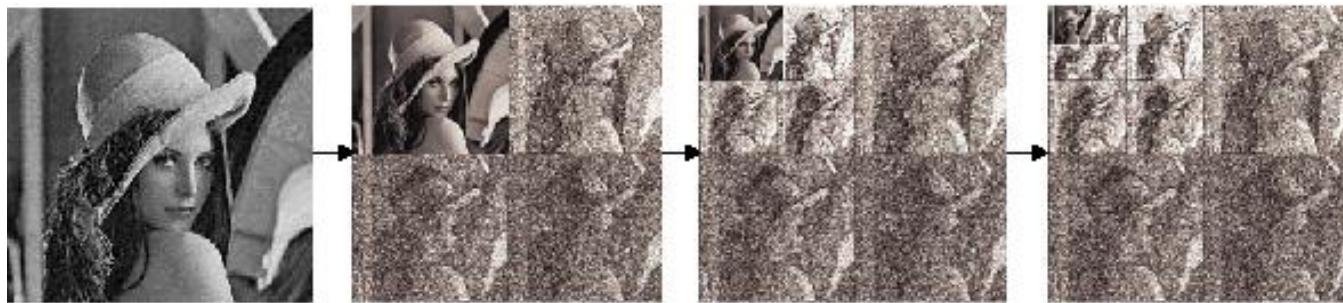
Res 1: Res 0 +  
LH3 + HL3 + HH3

Res 2: Res 1 +  
LH2 + HL2 + HH2

Res 3: Res 2 +  
LH1 + HL1 + HH1



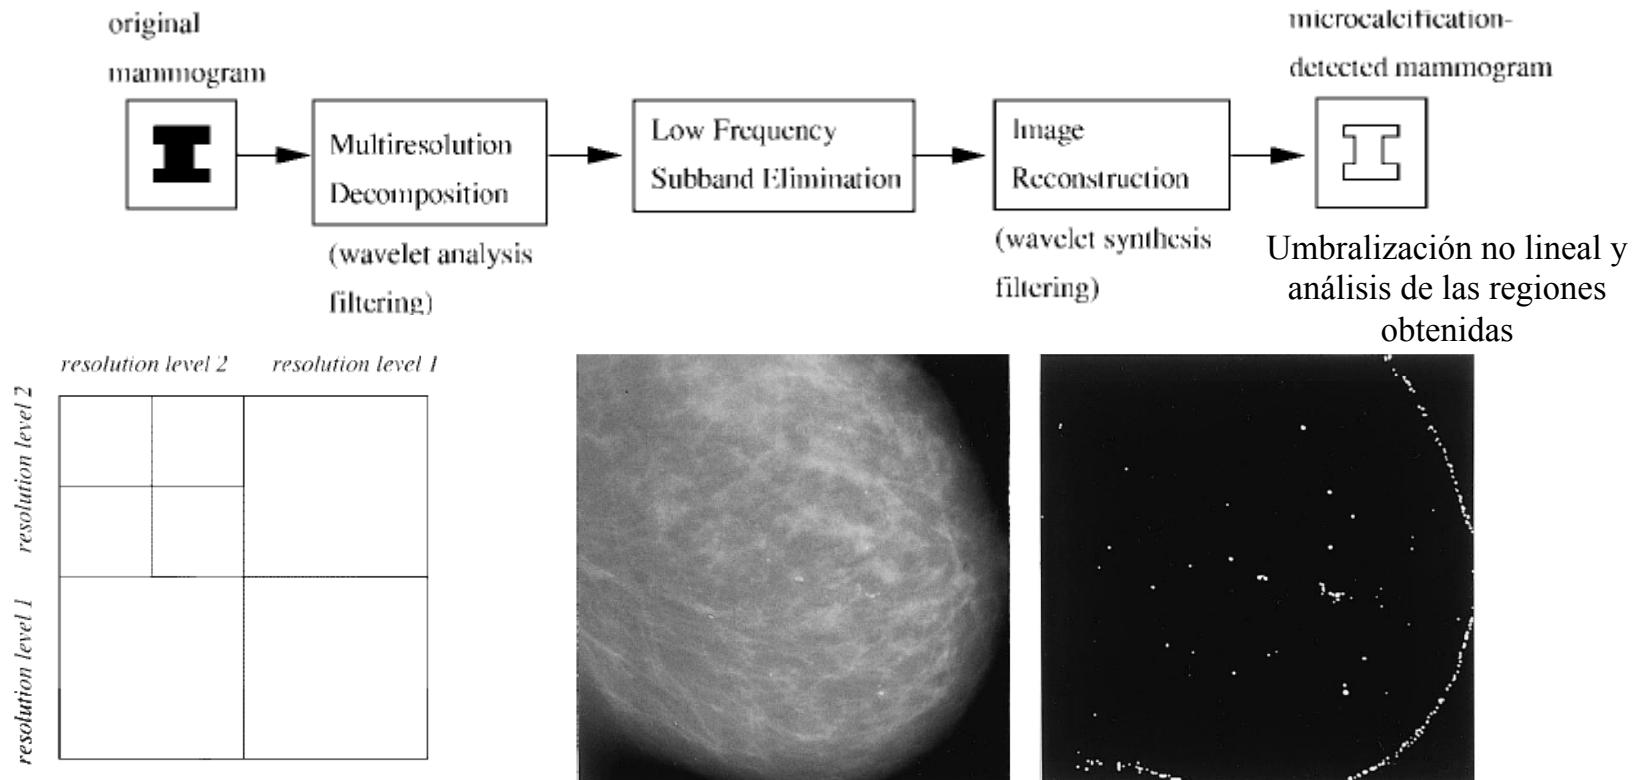
La resolución varía por la operación de filtrado y la escala por operaciones de submuestreo.



Al finalizar el proceso se obtienen un conjunto de sub-bandas: una de las sub-bandas contiene la aproximación a la imagen y el resto de sub-bandas contienen los detalles.

# Ejemplo: Detección de microcalcificaciones

**Hipótesis:** Las microcalcificaciones corresponden a componentes de AF. Los autores proponen descomponer la imagen en 2 niveles de resolución, poner a cero todos los coeficientes de aproximación, y reconstruir nuevamente la imagen  $\Rightarrow$  se espera que la imagen sólo contenga componentes de AF, incluyendo las microcalcificaciones.

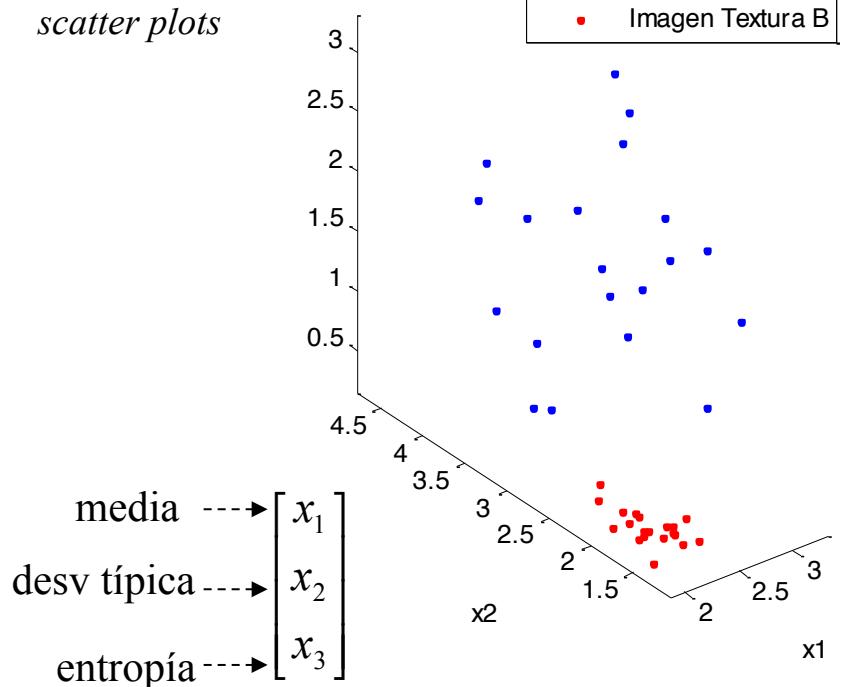
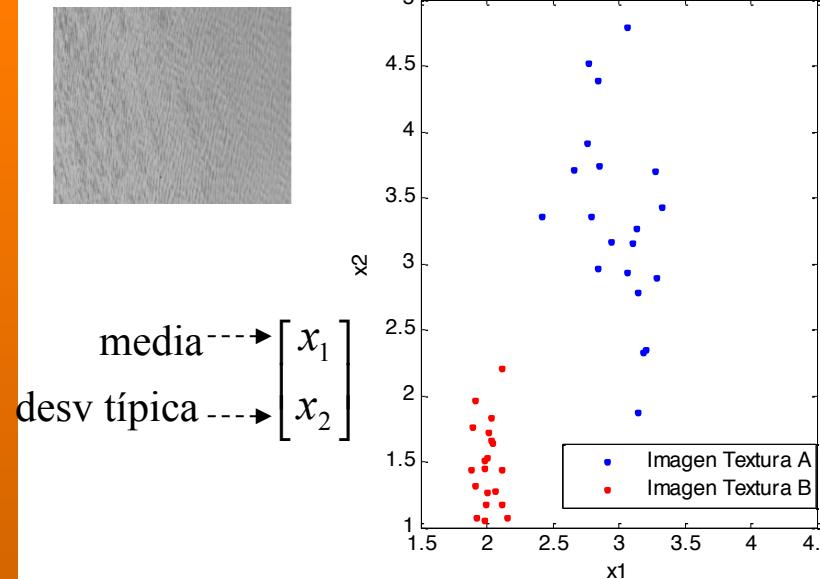


T.C. Wang, N.B. Karayiannis. Detection of microcalcifications in digital mammograms using wavelets. IEEE Trans. on Medical Imaging, vol. 17, no. 4, August 1998.

# Clasificación estadística (I)

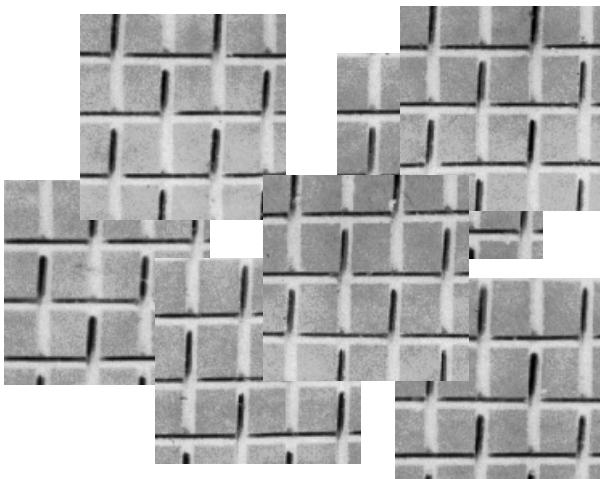
La segmentación de imagen se puede abordar también desde la perspectiva de la clasificación estadística  $\Rightarrow$  el objetivo es encontrar una función (clasificador) que permita separar/segmentar/clasificar distintos elementos, donde cada elemento está descrito a partir de un conjunto de características (o descriptores).

Por ejemplo, de la imagen asociada a una determinada textura se pueden obtener 2 descriptores (media, desviación típica), o 3 descriptores (media, desviación típica, entropía), o 4 descriptores .... De este modo, la imagen pasa a estar representada como un punto en un espacio de tantas dimensiones como descriptores se hayan extraído.

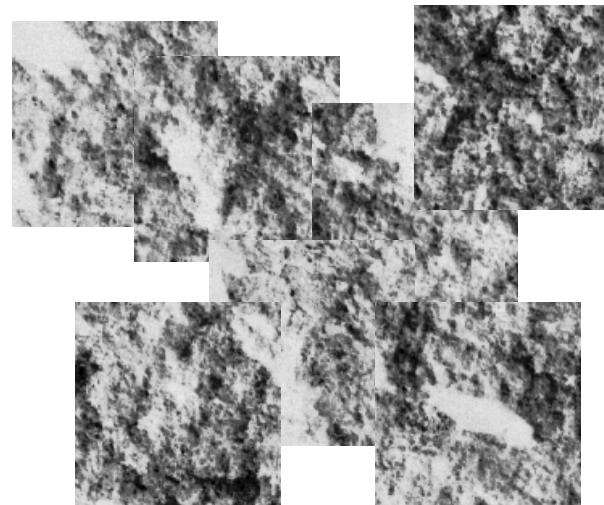


## Clasificación estadística (II)

Para realizar la clasificación o segmentación, se puede utilizar la información estadística proporcionada por un conjunto de imágenes de las que se conocen tanto sus descriptores como el “objeto tipo” al que pertenecen. Por ejemplo, para dos tipos de texturas distintas, donde se dispone de un conjunto de 7 imágenes para cada textura, tendríamos:

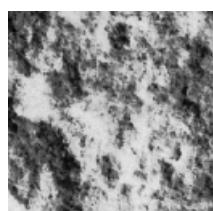


Textura A



Textura B

Este tipo de clasificación estadística se denomina supervisada, porque para diseñar la función de clasificación se utiliza la información sobre la textura (A ó B) a la que corresponden las características extraídas de cada imagen.



Clasificador o  
Segmentador de texturas

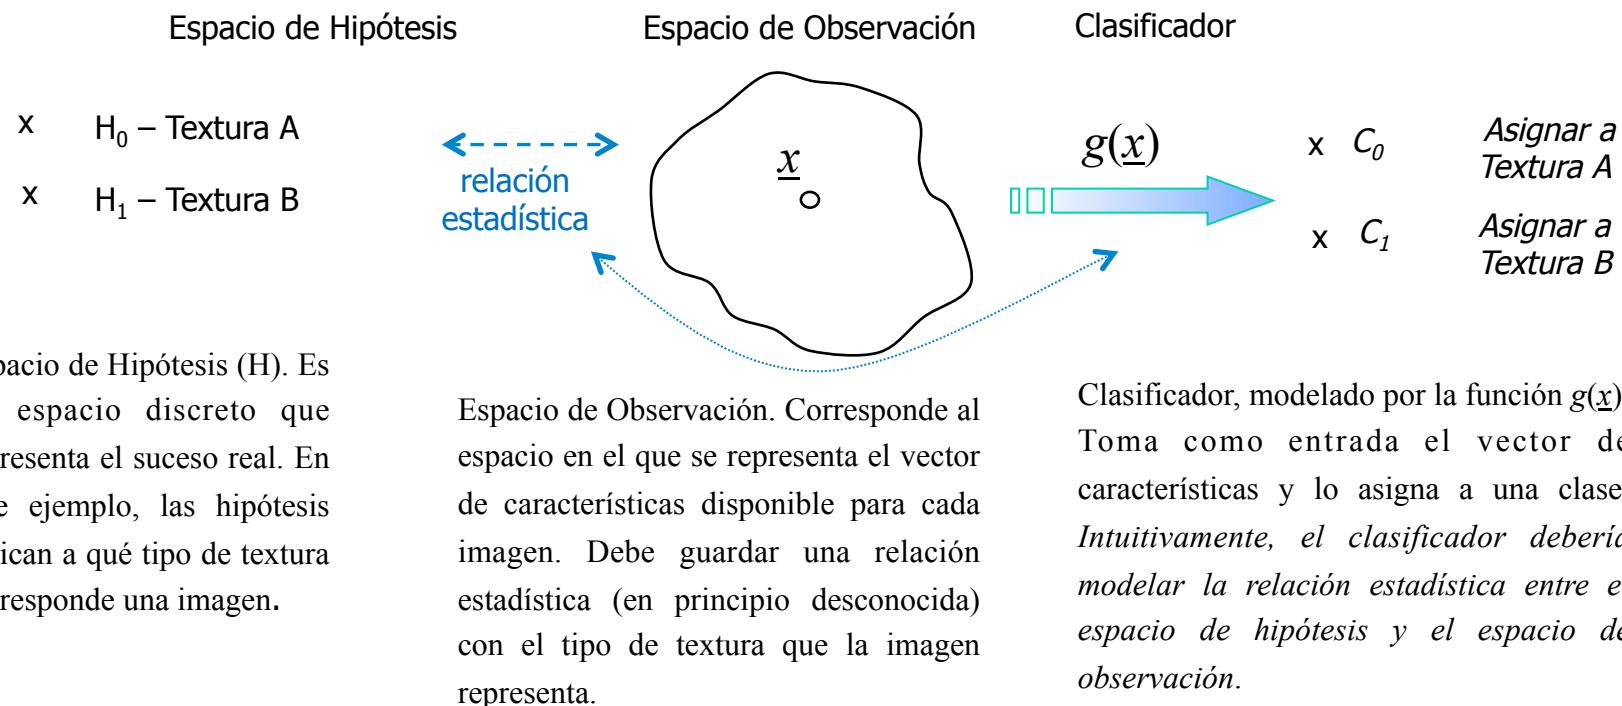


Textura B

# Clasificación estadística (III)

En este ejemplo, la tarea de **clasiﬁcación** consiste en asignar cada textura, descrita en términos de atributos o características (y que representamos por un vector de características  $\underline{x}$  al que también se denomina muestra u observación), a una de entre un conjunto ﬁnito de clases o categorías. La asignación se realiza a través de una función  $g(\cdot)$  que depende de  $\underline{x}$ .

Como en el ejemplo anterior (clasiﬁcación de texturas) sólo hay 2 clases (Textura A y Textura B), a esta tarea también se le denomina como de **clasiﬁcación binaria o decisión**.

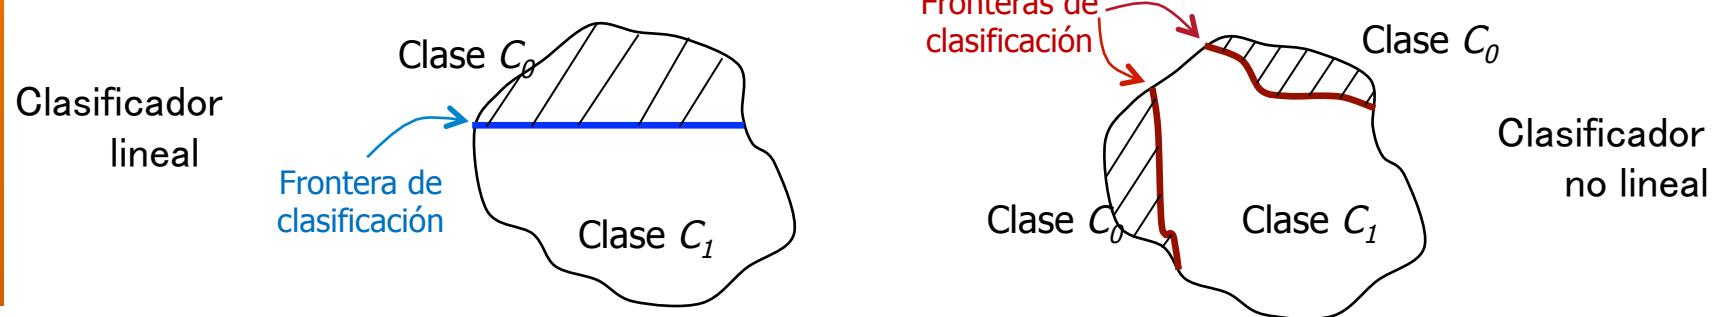


# Clasificación estadística (IV)



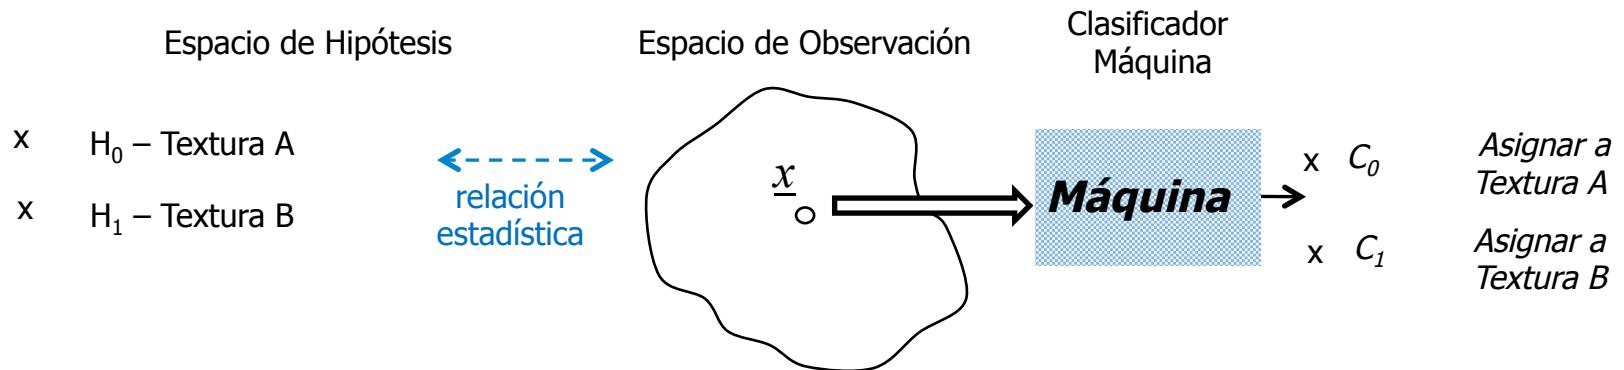
Un clasificador ideal proporcionaría a su salida la clase  $C_0$  cuando la imagen (representada por el vector  $\underline{x}$ ) correspondiera a la Textura A (hipótesis cierta  $H_0$ ), y la clase  $C_1$  cuando la imagen correspondiera a la Textura B (hipótesis  $H_1$ ).

- El clasificador divide el espacio de observación en regiones, cada una asociada a una única clase.
- A los límites entre regiones contiguas asociadas a clases diferentes se les denomina fronteras (de clasificación).



# Clasificación Máquina Supervisada (I)

- Idea de la clasificación máquina: Diseñar una “máquina” (función  $g(\cdot)$ ) que divida el espacio de observación de la mejor forma posible. Para ello, la máquina tiene un conjunto de parámetros que es necesario ajustar o aprender a partir de un conjunto de observaciones (conjunto de – ejemplos de - entrenamiento).

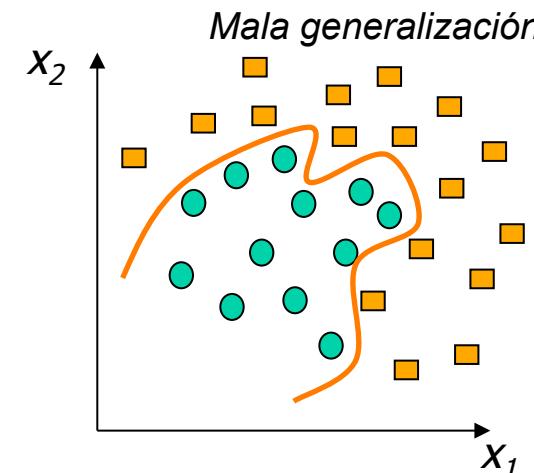
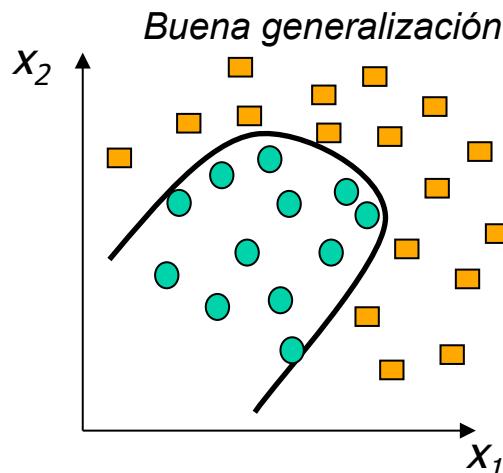


- El diseño de un clasificador “máquina” utilizando un esquema supervisado hace uso de un conjunto  $S$  formado por  $N$  pares de variables
- La variable  $\underline{x}$  corresponde al vector de características de cada observación (entrada a la máquina)
- La variable  $t$  indica la clase (*target*) a la que pertenece la observación correspondiente (y que es la salida deseada/óptima de la máquina).

$$S = \left\{ \underline{x}^{(n)}, t^{(n)} \right\}_{n=1}^N$$

## Clasificación Máquina Supervisada (II)

- Si el conjunto de entrenamiento también se utilizara para evaluar las prestaciones del clasificador, éstas se sobreestimarían (es decir, parecería que el clasificador es muy bueno). Es por esta razón que, para evaluar la bondad del clasificador, se utiliza un conjunto de datos independiente del conjunto de aprendizaje y al que se denomina conjunto de prueba o de test.
- Interesa que la máquina ofrezca buena capacidad de generalización; es decir, que sea capaz de generalizar el conocimiento adquirido tras el aprendizaje, proporcionando una respuesta correcta ante ejemplos no utilizados para diseñar el clasificador (conjunto de entrenamiento *versus* conjunto de test).
- Ejemplo: Problema de decisión bidimensional (vector de características  $\underline{x}$  formado por dos elementos:  $x_1$  y  $x_2$ ). Se muestra el conjunto de aprendizaje, donde cada clase se representa con un símbolo y color diferente.



# Clasificación Máquina utilizando $k$ -NN (I)

La técnica de los  $k$  vecinos más próximos o  $k$ -nn ( $k$ -nearest neighbours) permite diseñar clasificadores utilizando un conjunto de  $N$  ejemplos denominado conjunto de entrenamiento (de diseño, o de aprendizaje). Cada ejemplo (observación) del conjunto de diseño está formado por un vector de características  $\underline{x}$  y una etiqueta  $t$  que indica a qué clase pertenece. Por ejemplo, si tuviéramos  $N = 150$  imágenes de texturas asociadas a tres tipos de texturas diferentes (ladrillo, paja, agua), donde cada textura estuviera descrita en términos de 4 características, tendríamos un conjunto de datos del siguiente tipo ...

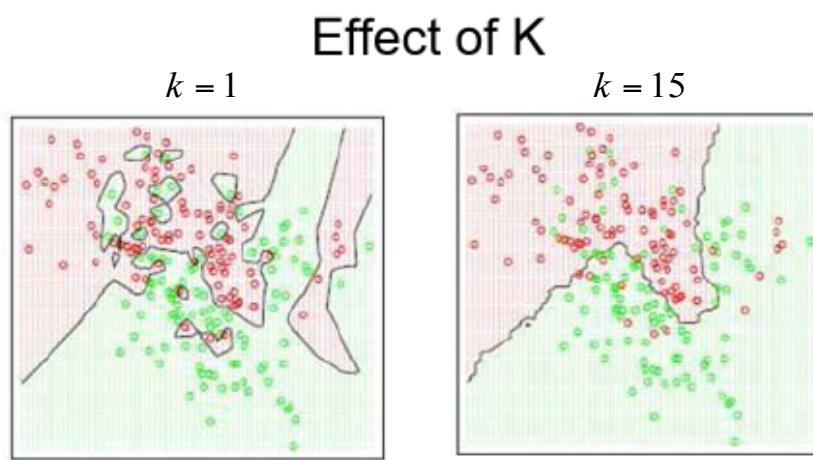
$\{\underline{x}^{(n)}, t^{(n)}\}_{n=1}^N$	$n=1$	Media	Desv. Típica	Entropía	Suavidad rel	Tipo Textura		
		$\underline{x}^{(1)}$	5.1	3.5	1.4	0.2	ladrillo	$t^{(1)}$
			4.9	3.0	1.4	0.2	ladrillo	
	$n=3$	$\underline{x}^{(3)}$	4.7	3.2	1.3	0.2	paja	$t^{(3)}$
			...	...	...	...		
			7.0	3.2	4.7	1.4	paja	
			...	...	...	...		
			6.3	3.3	6.0	2.5	agua	
	$n=150$		...	...	...	...		

Existen varias variantes del clasificador  $k$ -NN. Todas ellas se basan en una medida de distancia (de manera general se utiliza la distancia Euclídea), y utiliza el conjunto de datos que se muestra en la tabla anterior para segmentar una nueva imagen en una de las texturas que aparecen en la base de datos.

# Clasificación Máquina utilizando $k$ -NN (II)

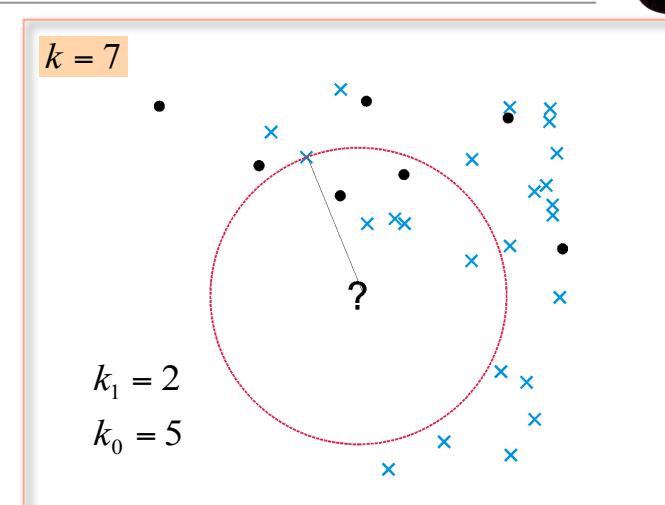
Los clasificadores de tipo  $k$ -NN tienen un único parámetro:  $k$ , que es el número de vecinos más próximos (de entre los del conjunto de diseño) para clasificar un nuevo ejemplo.

El clasificador  $k$ -NN más sencillo es el denominado clasificador  $k$ -NN por votación (*voting k*-NN).



Larger  $k$  produces smoother boundary effect and can reduce the impact of class label noise.

But when  $k$  is too large, say  $k=N$ , we always predict the majority class



**CLASIFICADOR 7-NN POR VOTACIÓN**  
Ejemplo con 2 clases y 2 dimensiones

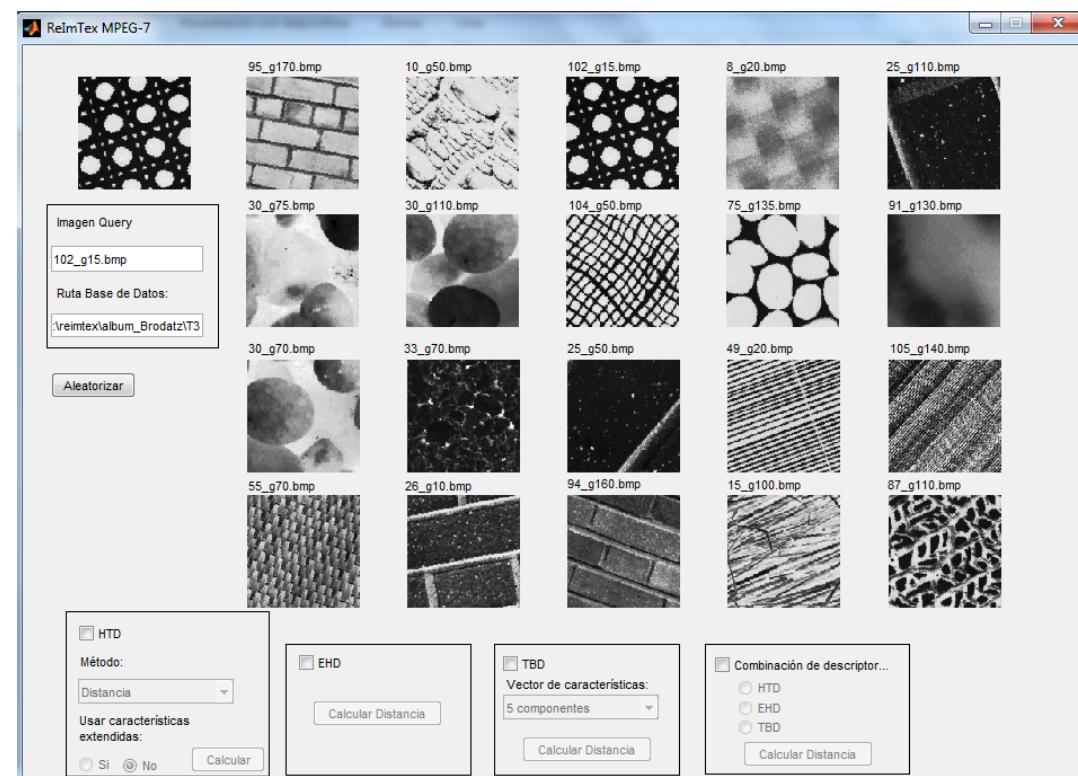
Para clasificar un nuevo ejemplo (“?”):

- Situar “?” (el nuevo ejemplo) en el espacio de representación.
- Obtener su distancia a cada ejemplo del conjunto de diseño.
- Identificar los  $k$  ejemplos más próximos (más parecidos) y asignar “?” a la clase mayoritaria (votación por mayoría).

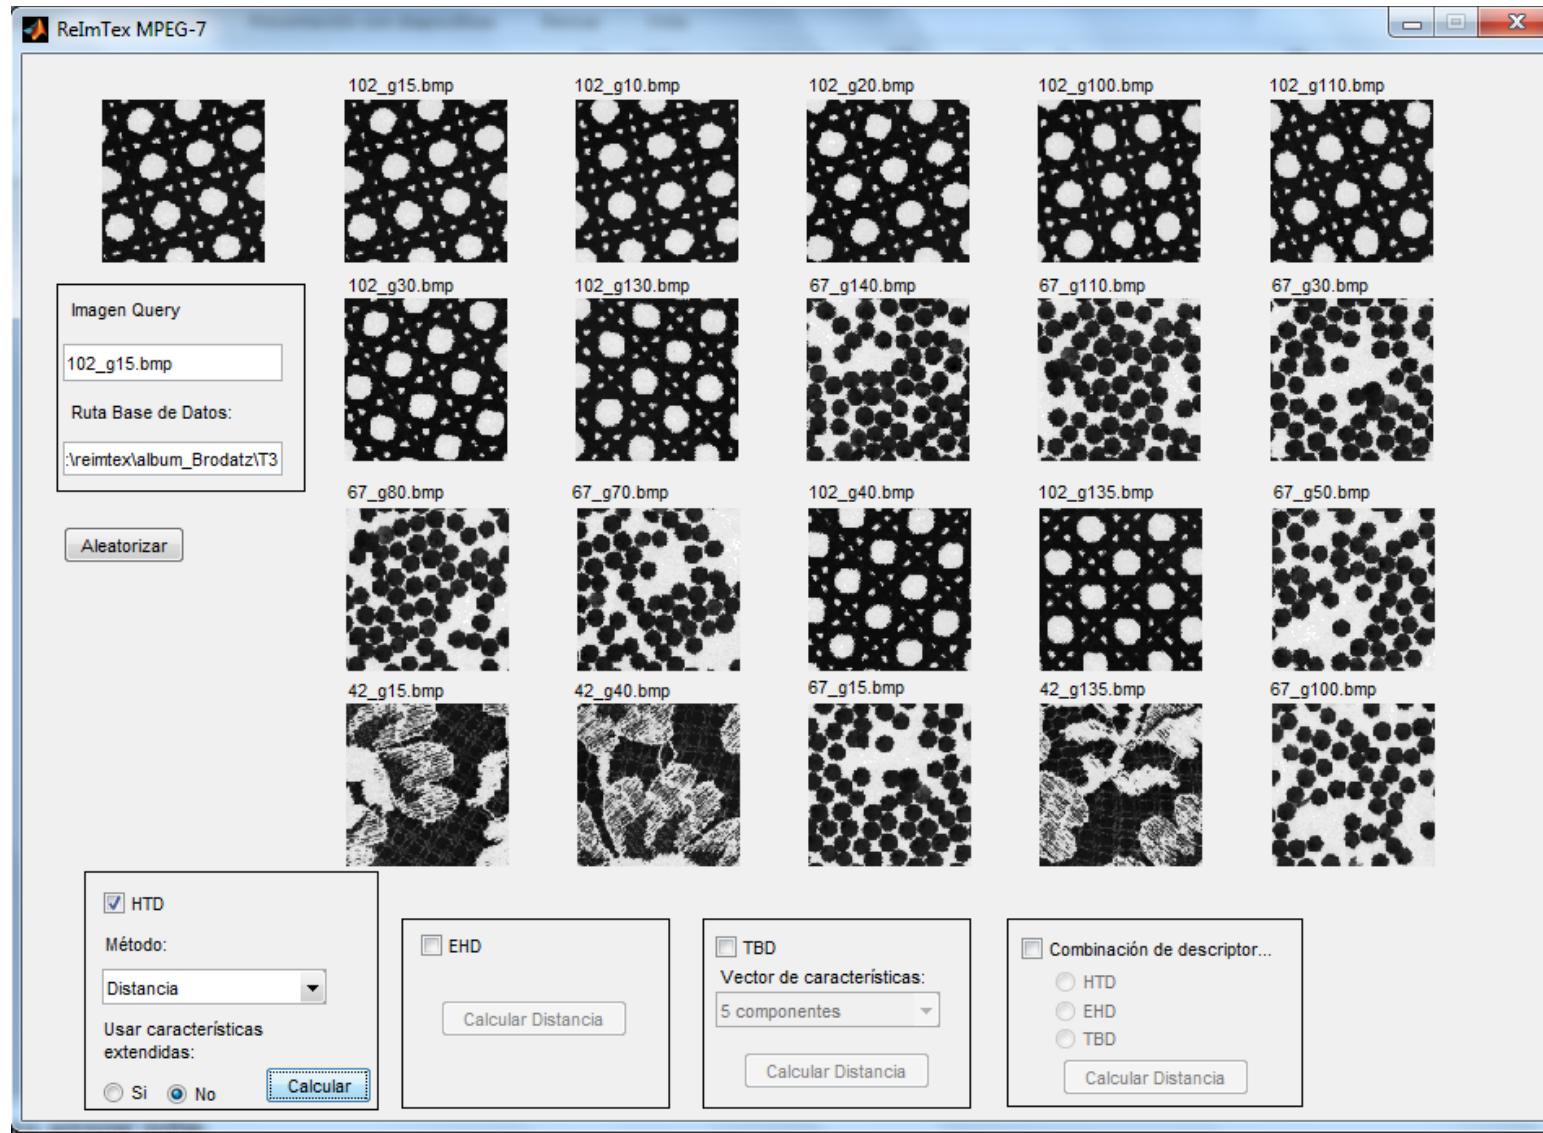
## Ejemplo 1: Búsqueda de imágenes basada en contenido

- Se parte de una representación del contenido visual de las imágenes a partir de su propio contenido, sin contar con “indexadores” dedicados a plasmar en pocas palabras lo que representa la imagen.
- Para caracterizar una imagen en función de su contenido se utilizan descriptores (características), relacionados con las propiedades de la imagen (color, textura, ...)

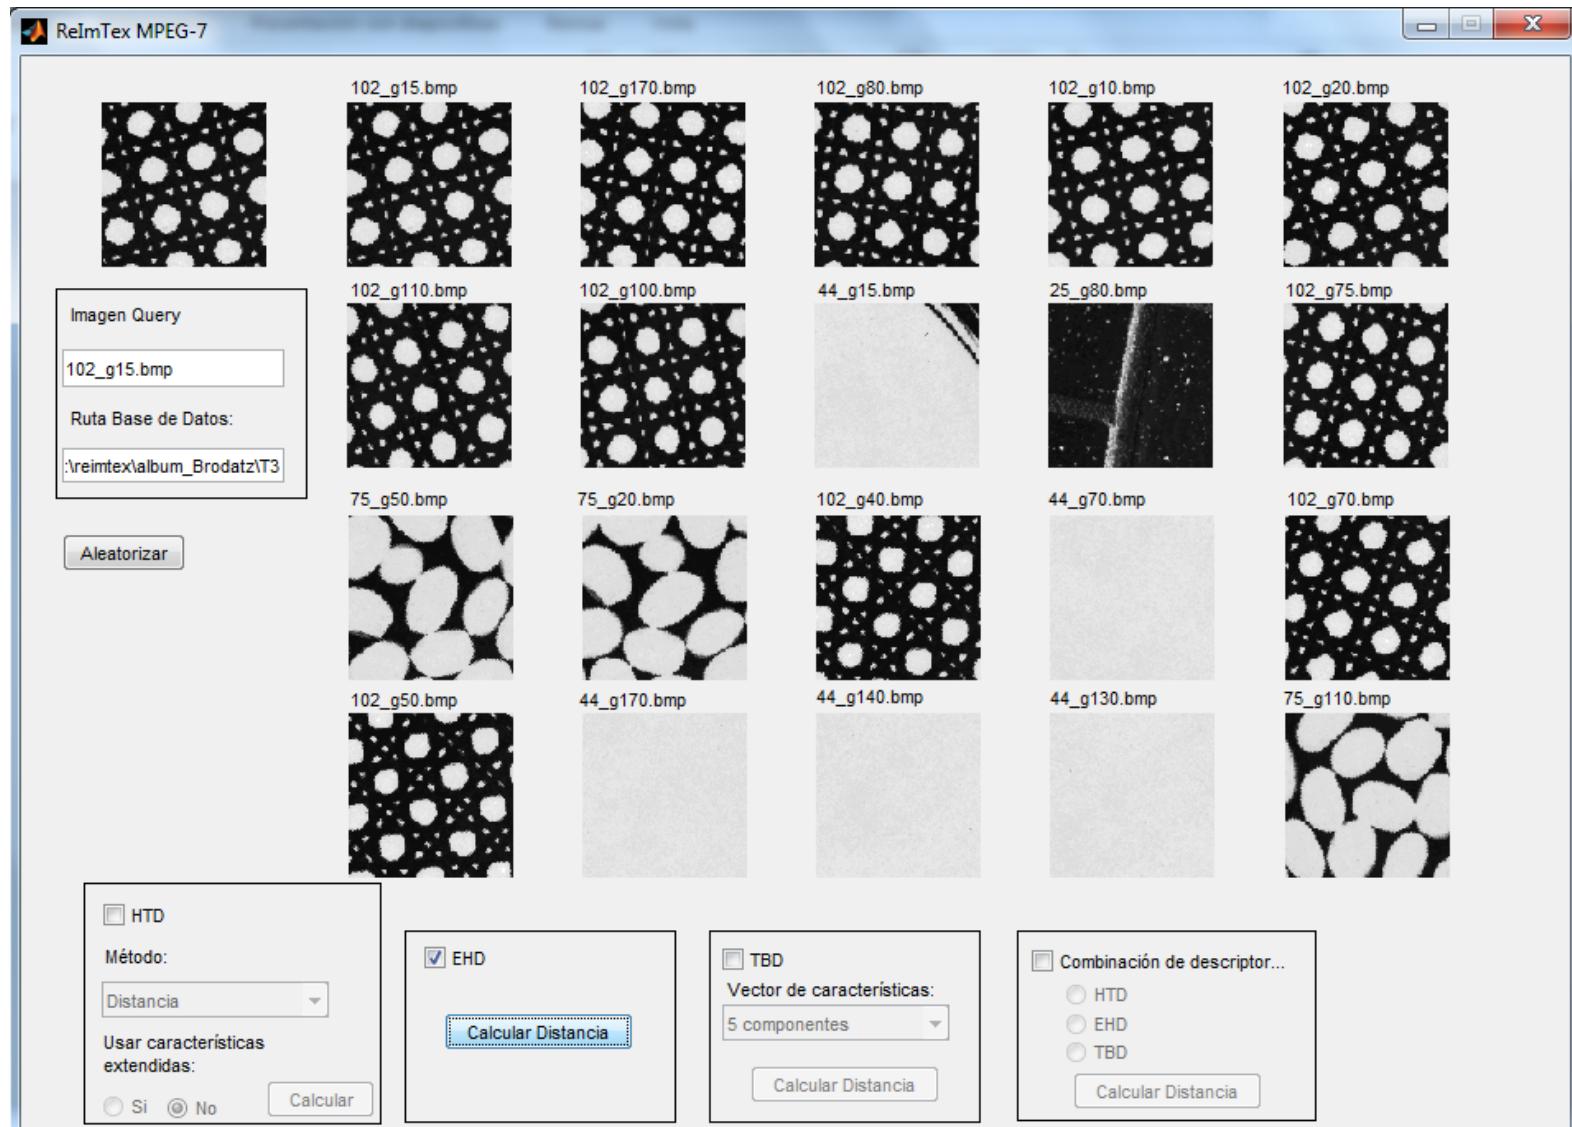
- El siguiente ejemplo utiliza descriptores de textura de *bajo nivel*, definidos en el estándar MPEG-7



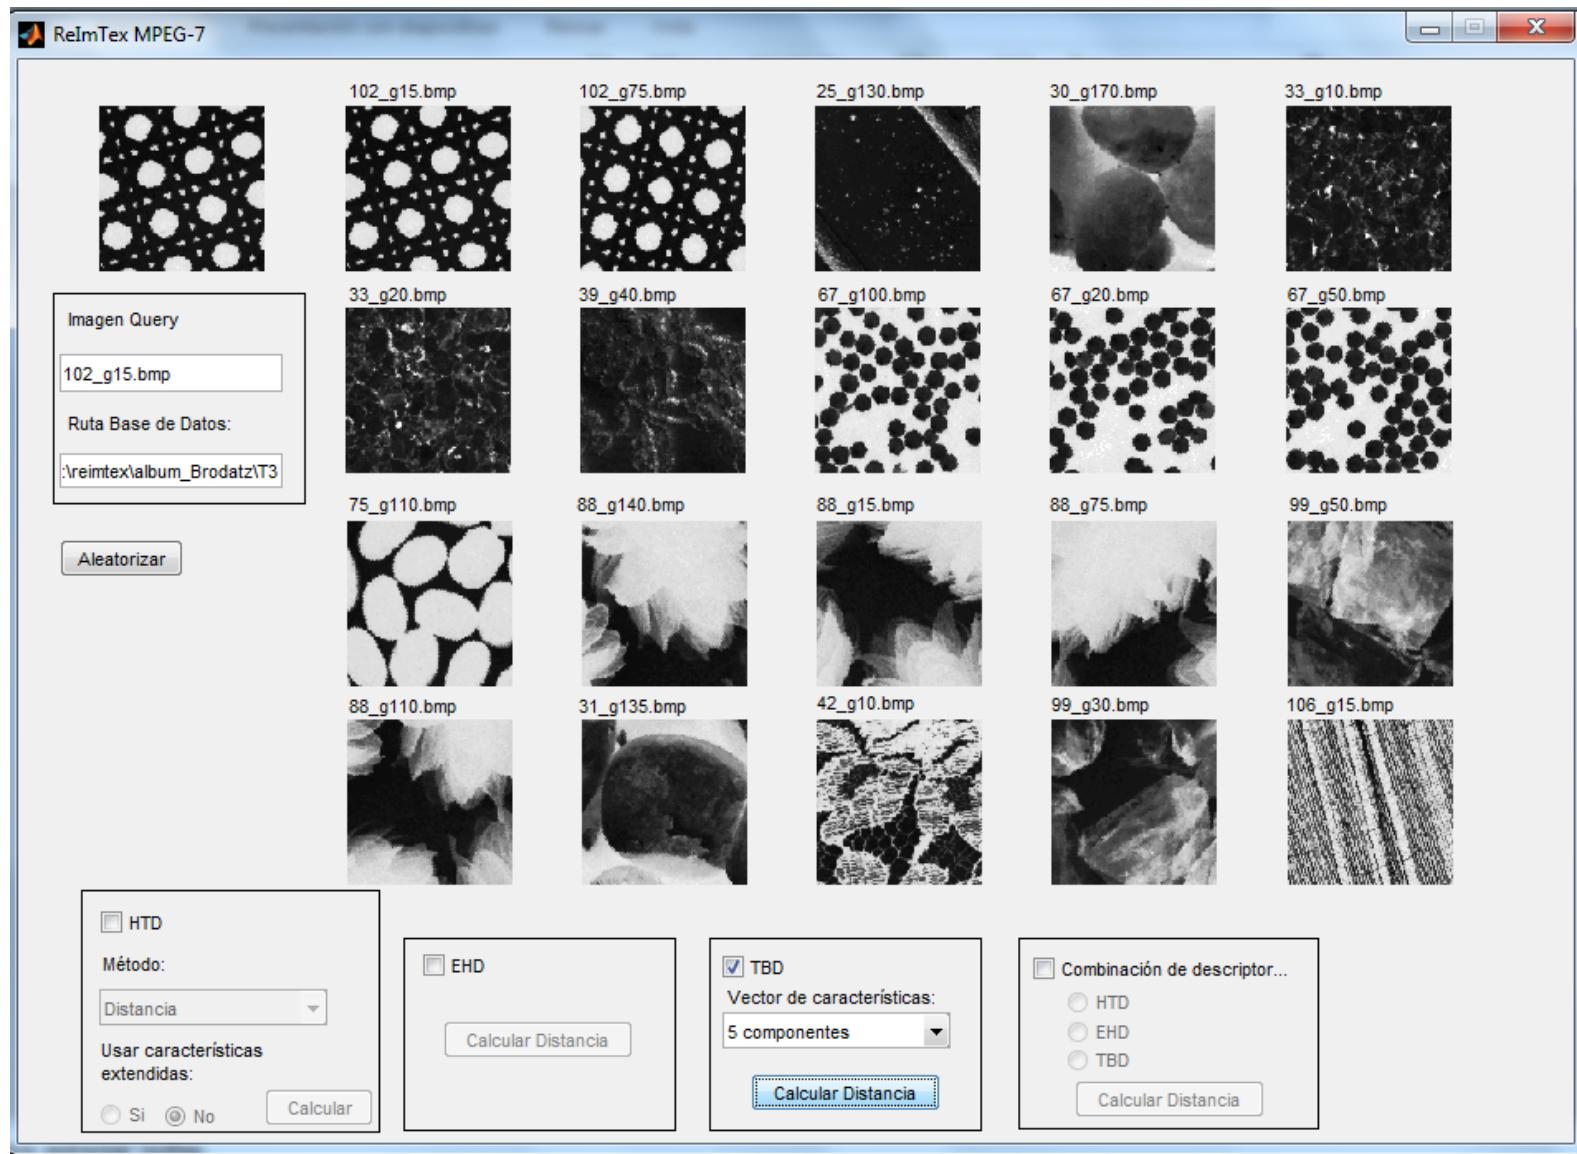
## Ejemplo 1: Búsqueda de imágenes basada en contenido (II)



## Ejemplo 1: Búsqueda de imágenes basada en contenido (III)



## Ejemplo 1: Búsqueda de imágenes basada en contenido (IV)



## Ejemplo 2: Segmentación del endocardio en imágenes de TAC (I)

Músculo cardíaco

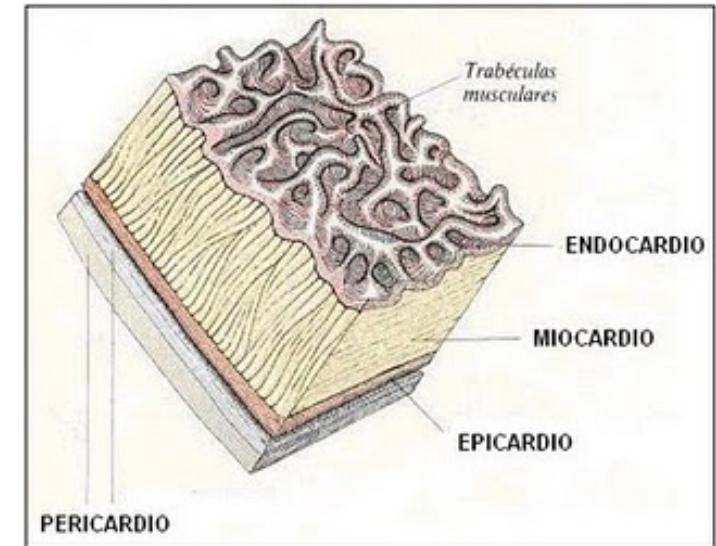
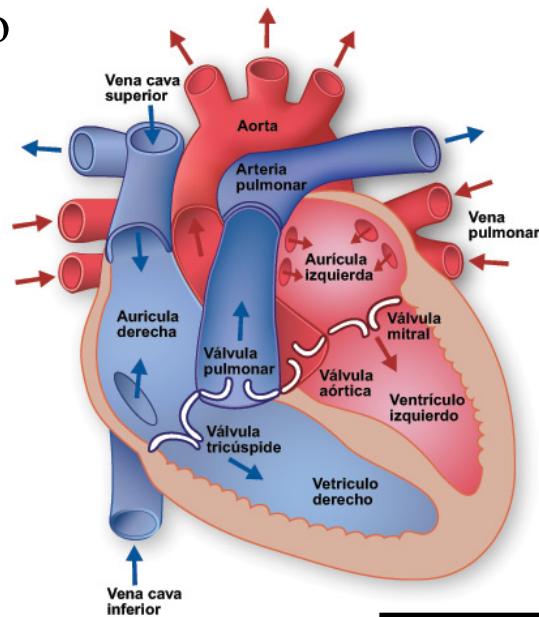
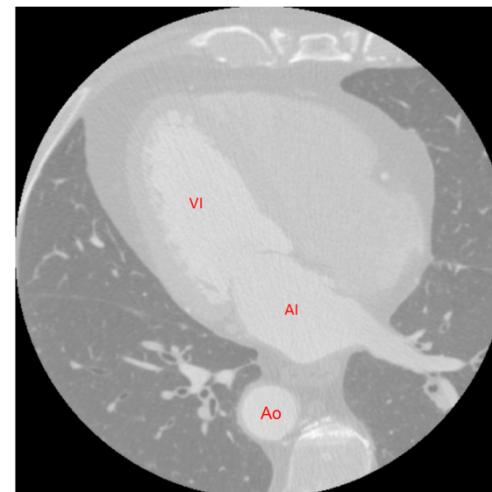


Imagen médica a través de  
TAC (Tomografía Axial  
Computarizada )



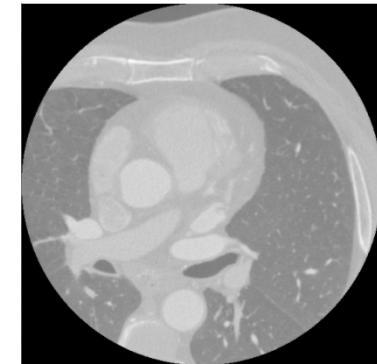
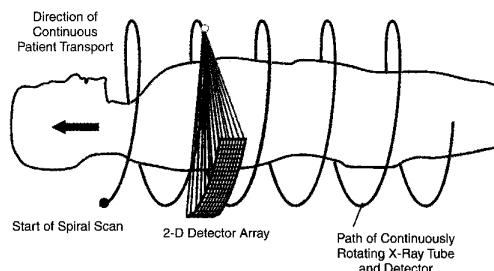
## Ejemplo 2: Segmentación del endocardio en imágenes de TAC (II)

TAC: Técnica no invasiva basada en rayos X



*Escáner TAC*

El número CT asociado a la sangre se modifica inyectando una sustancia yodada que hace aumentar la absorción de los rayos X por parte de la sangre. De esta manera, el músculo cardíaco y las cavidades contrastadas están diferenciadas con números CT distintos.



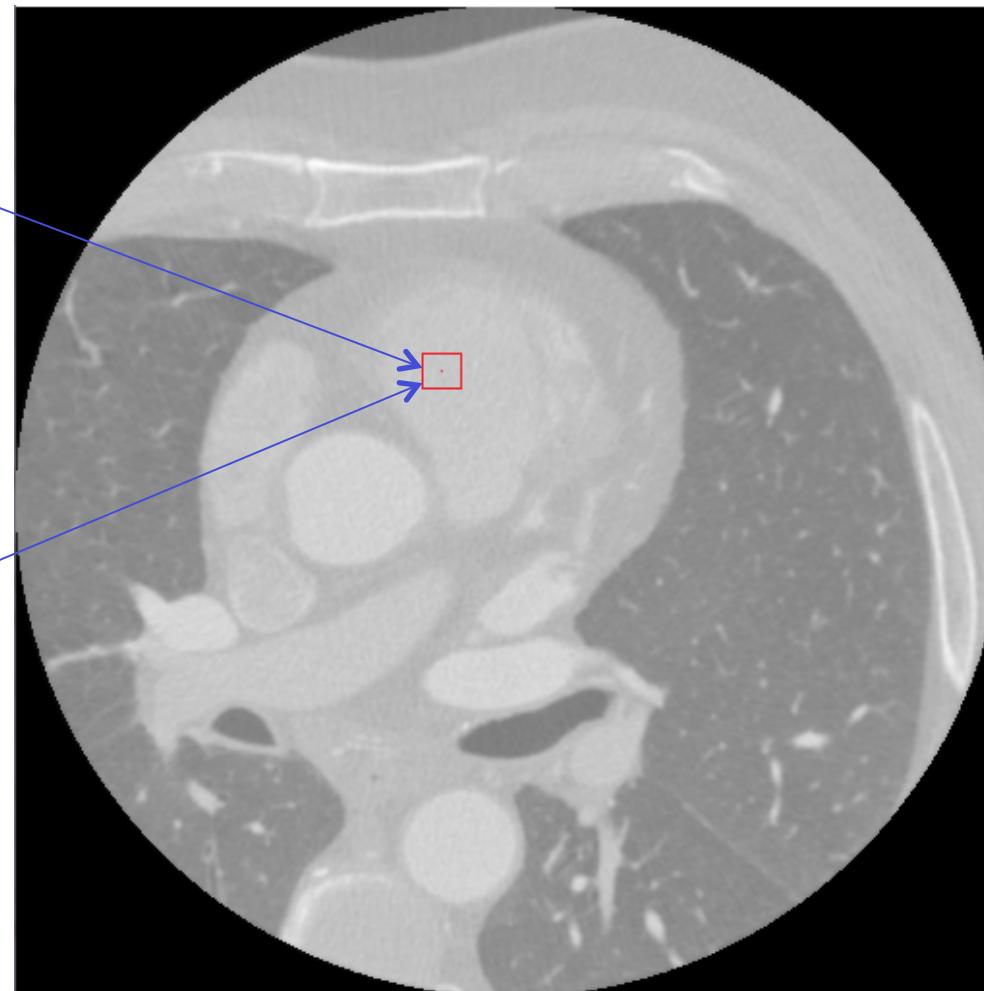
*Slice de TAC*

Tejido	Número CT
Hueso	1000
Hígado	40 a 60
Materia blanca	20 a 30
Materia gris	37 a 45
Sangre	40
Riñones	30
Músculo	10 a 40
Fluido cerebroespinal	15
Agua	0
Grasa	50 a 100
Aire	1000

## Ejemplo 2: Segmentación del endocardio en imágenes de TAC (III)

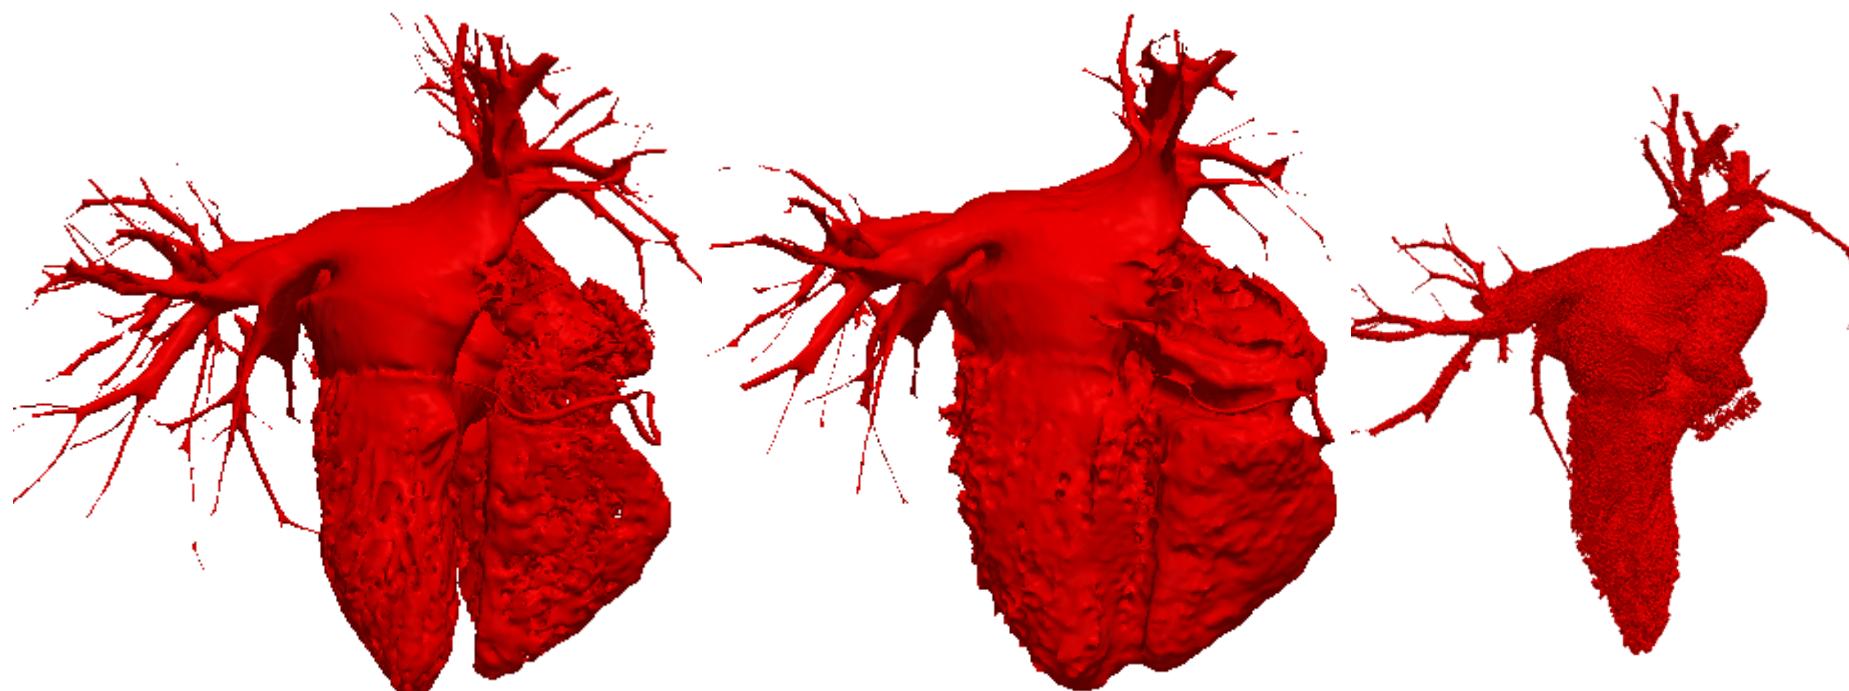
Textura

Ventana



## Ejemplo 2: Segmentación del endocardio en imágenes de TAC (IV)

Se han utilizado 66 descriptores diferentes para analizar las texturas de los tejidos. Se realiza segmentación estadística con algunos de esos descriptores, utilizando tanto ventanas 2D (*slice a slice*) como ventanas 3D (considera una vecindad en 3 *slices* simultáneamente) y técnicas de aprendizaje más elaboradas que *k*-NN.



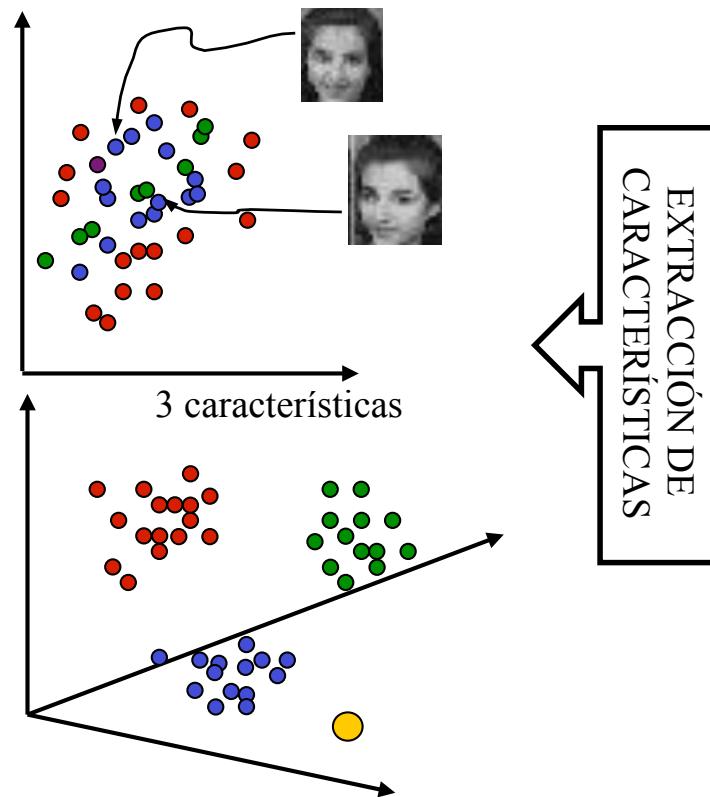
Vecindad a 8

Vecindad a 26

Entrenada para el VI

## Ejemplo 3: Sistema de reconocimiento facial

2 características (espacio de representación bi-dimensional)



**IDEA:** construir un sistema de representación donde las *imágenes* (representadas por un vector de características) de un mismo individuo estén *próximas*, y en una región del espacio de representación diferente a la región donde se *encuentran* las imágenes de otro individuo.

Base de datos de diseño



Cada imagen se considera como un punto (un vector de características) en un espacio.

Imagen de test



Sistema de reconocimiento de caras



Identidad

