

Tema 3: Segmentación

3.1. Introducción. Elementos y terminología

3.2. Segmentación de imágenes binarias

3.3. Segmentación de imágenes en escala de gris

3.4. Segmentación de imágenes en color

3.5. Técnicas estadísticas. **Análisis de Componentes Principales (PCA). Aplicación a segmentación de imágenes en color y a imágenes multispectrales**

Segmentación aplicando una transformación lineal PCA



PCA (“*Principal Component Analysis*”) es una técnica que permite descomponer una señal \underline{x} descrita en términos de m componentes $[x_1, x_2, \dots, x_m]$ como una combinación lineal de otras m componentes $\underline{f} = [f_1, f_2, \dots, f_m]$ denominadas componentes principales.

$$\begin{array}{c} \text{Componentes} \\ \text{principales} \end{array} \rightarrow \begin{bmatrix} f_1 \\ f_2 \\ \vdots \\ f_m \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & \cdot & \cdot & a_{1m} \\ a_{21} & a_{22} & \cdot & \cdot & a_{2m} \\ \cdot & \cdot & \cdot & \cdot & \cdot \\ a_{m1} & a_{m2} & \cdot & \cdot & a_{mm} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix} \leftarrow \begin{array}{c} \text{Atributos o} \\ \text{componentes} \\ \text{originales} \end{array}$$

PCA combina **linealmente** las componentes del vector \underline{x} para obtener otro conjunto de atributos (representado por el vector \underline{f}) denominado componentes principales.

Las nuevas componentes se generan de tal manera que están incorreladas entre sí y, además, las primeras componentes tienen más relevancia que las últimas (f_1 tiene más relevancia – en el sentido de varianza - que f_2, \dots).

Como consecuencia, ignorar las últimas componentes implica descartar la información menos relevante (y viceversa) \Rightarrow útil para reducir el número de componentes.


PCA también se puede utilizar para transformar las componentes originales en otras más adecuadas para aplicar técnicas de clasificación/segmentación.

Segmentación aplicando una transformación lineal PCA



Geométricamente, PCA se puede interpretar como un cambio de ejes en la representación (proyección).

Ejemplo para dos atributos o componentes:



x_1, x_2 : componentes originales
 f_1, f_2 : componentes principales
(componentes transformadas)

Para obtener las componentes principales:

- se utiliza la matriz de covarianza $C|_{m \times m}$ de los m atributos originales. Esta matriz indica la relación lineal entre las distintas componentes.
- se obtienen los correspondientes autovalores (*eigenvalues* $\{\lambda_i\}$) y autovectores (*eigenvectors* $\{f_i\}$, $i=1, \dots, m$).
- el autovector asociado al mayor autovalor determina la transformación lineal óptima (primera componente principal).

Segmentación aplicando una transformación lineal PCA



Asociado a cada autovalor (*eigenvalue*) hay un autovector (*eigenvector*). Como en el ejemplo anterior, $m=2$:

$$\lambda_1 \rightarrow f_1$$


$$\lambda_2 \rightarrow f_2$$

$$\lambda_1 > \lambda_2$$

f_1 es primera componente principal

f_2 es segunda componente principal

¿Significado de los autovalores y autovectores?



Los **autovectores** (f_1, f_2, \dots) de la matriz de covarianza marcan la orientación preferente de la distribución.



indican las direcciones de mayor “información”

Los **autovalores** (λ_1, λ_2) de la matriz de covarianza indican la varianza en la dirección de los correspondientes autovectores.



indican qué proporción de la variabilidad original contiene la nueva característica

Segmentación aplicando una transformación lineal PCA



Aplicación de PCA a la segmentación de imágenes en color

- Cada píxel se considera como un punto \underline{x} en un espacio 3D, donde cada elemento del vector corresponde a una de las componentes de color (i.e, $m=3$)

$$\text{píxel} \Rightarrow \text{punto } \underline{x} = [R, G, B]$$

- Se determina el valor medio de cada componente de color

$$E[R], E[G], E[B]$$

- Matriz de covarianza C (3x3)

$$C = \begin{pmatrix} c_{rr} & c_{rg} & c_{rb} \\ c_{gr} & c_{gg} & c_{gb} \\ c_{br} & c_{bg} & c_{bb} \end{pmatrix}$$

$$\text{donde } c_{gr} = \frac{1}{N_{\text{píxeles}}} \sum_{i=1}^{N_{\text{píxeles}}} (G_i - E[G])(R_i - E[R])$$



Segmentación aplicando una transformación lineal PCA



- Se determinan los autovalores y autovectores de la matriz C
- El autovector asociado al mayor autovalor, determina la transformación lineal óptima.

Ejemplo de la señal vial.

$$\lambda_1 = 2.7674 \quad \mathbf{a}_1 = [-0.5651 \quad 0.8199 \quad 0.0912]$$

$$\lambda_2 = 0.1720 \quad \mathbf{a}_2 = [-0.5855 \quad -0.3208 \quad -0.7445]$$

$$\lambda_3 = 0.0606 \quad \mathbf{a}_3 = [-0.5812 \quad -0.4741 \quad 0.6614]$$

$$\begin{bmatrix} f_1 \\ f_2 \\ f_3 \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \begin{bmatrix} R \\ G \\ B \end{bmatrix}$$

$$\lambda_1 \text{ explica el } 92.24\% \text{ de la varianza } \frac{\lambda_1}{\sum_{i=1}^3 \lambda_i} 100$$

λ_1 y λ_2 explican el 97.97% de la varianza

Combinación lineal óptima: $f_1 = -0.5651 R + 0.8199 G + 0.0912 B$

(óptima en el sentido de mayor variabilidad,
pero puede que no sea la mejor componente
para segmentar por umbralización)


Segmentación aplicando una transformación lineal PCA




PCA - Transformación lineal



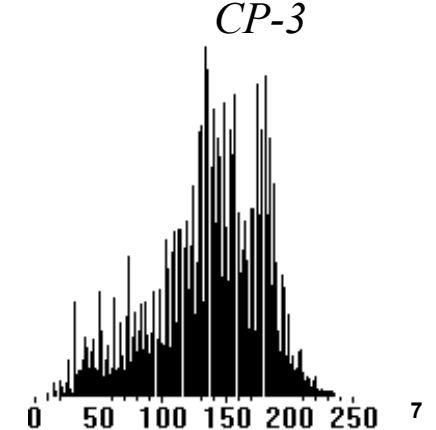
CP-1



CP-2




CP-3



Segmentación aplicando una transformación lineal PCA




CP-2



Umbral = 100




AND del resultado de la umbralización con valor 100 y la imagen RGB



Umbral = 200

(obtenemos mejor segmentación que con la componente S del modelo HSI)




Aplicación de PCA sobre imágenes multiespectrales

PCA también se puede aplicar sobre imágenes multiespectrales, en Teledetección, para preservar la información esencial en un menor número de dimensiones (imágenes).

El ojo humano sólo es sensible a las ventanas electromagnéticas asociadas al rojo, verde y azul. Sin embargo, los sistemas de teledetección son sensibles a otras longitudes de onda \Rightarrow imágenes en varias bandas espectrales (imágenes multiespectrales). Puesto que las longitudes de onda están próximas, es habitual que las imágenes multiespectrales contengan información redundante.

Ejemplo: seis de las ocho bandas registradas por el sensor ETM de Landsat 7



B

G

R


IR

1.0000	0.9931	0.9639	0.4896	0.8420	0.8486
0.9931	1.0000	0.9835	0.4929	0.8917	0.8889
0.9639	0.9835	1.0000	0.3723	0.9274	0.9368
0.4896	0.4929	0.3723	1.0000	0.4078	0.2494
0.8420	0.8917	0.9274	0.4078	1.0000	0.9651
0.8486	0.8889	0.9368	0.2494	0.9651	1.0000

Matriz de correlación lineal

Como las nuevas componentes f se generan de tal manera que están incorreladas entre sí y, además, las primeras componentes tienen más relevancia \Rightarrow se puede pensar en ignorar las últimas componentes principales para descartar la información menos relevante \Rightarrow útil para reducir el número de componentes.

Aplicación de PCA sobre imágenes multispectrales



Aplicando PCA

f_1

f_2

f_3

f_4


f_5

f_6



Mayor variabilidad

Menor variabilidad



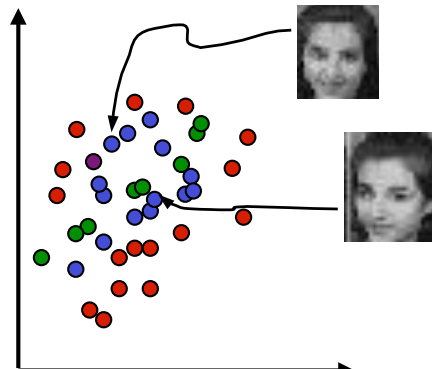
PCA se puede aplicar para preservar la información esencial contenida en la escena en un número menor de dimensiones (imágenes).

Las nuevas componentes se pueden utilizar con propósitos de visualización (creando imágenes en falso color) o para aplicar técnicas de clasificación (segmentación).


Ejemplo de un sistema de reconocimiento facial



2 características (espacio de representación bi-dimensional)



3 características



EXTRACCIÓN DE CARACTERÍSTICAS

Base de datos de diseño



Cada imagen se considera como un punto (un vector de características) en un espacio.

Imagen de test



Sistema de reconocimiento de caras

Identidad

Tres caras más parecidas



IDEA: construir un sistema de representación donde las *imágenes* (representadas por un vector de características) de un mismo individuo estén *agrupadas*, y el grupo al que pertenecen sea claramente diferente al grupo que representa las imágenes de otro individuo.

Ejemplo de un sistema de reconocimiento facial




- Cada imagen se considera como un punto (o un vector) en un espacio.
- El espacio de caras es muy redundante: todas las caras tienen componentes *parecidas*.
Objetivo: aplicar la técnica de PCA para extraer información facial relevante capturando la variación estadística entre las imágenes de caras almacenadas en una base de datos (base de datos de diseño).



Ejemplo de un sistema de reconocimiento facial



Una imagen se puede representar como una matriz de un tamaño determinado (h filas y w columnas). Esa matriz se puede representar en forma de un vector columna.


$$imagen_k = \begin{bmatrix} i_{11} & \cdots & i_{1w} \\ i_{21} & \cdots & i_{2w} \\ \vdots & \ddots & \vdots \\ i_{h1} & \cdots & i_{hw} \end{bmatrix}_{h \times w} \Rightarrow \begin{bmatrix} i_{11} \\ i_{21} \\ \vdots \\ i_{hw} \end{bmatrix}_{(h \times w) \times 1}$$

En este escenario, el espacio de representación tendrá dimensión $h \times w$, y sobre él se podrá representar cualquier imagen. Como medida de similitud entre imágenes se puede considerar una medida de distancia \Rightarrow imágenes parecidas estarán próximas en el espacio de representación.

Sin embargo, el “espacio de caras” es altamente redundante \Rightarrow desde el punto de vista computacional resulta interesante reducir la dimensión del espacio de representación.

Esta reducción se puede realizar aplicando un método de análisis de componentes principales (PCA) para encontrar una **base de vectores (autovectores)** que permita representar caras humanas de forma menos redundante. Al espacio formado con los nuevos vectores se le denomina **espacio de autocaras (eigenfaces)**.


Ejemplo de un sistema de reconocimiento facial



En álgebra lineal, los autovectores (*eigenvectors*) de un operador lineal son los vectores no nulos que, cuando son transformados por el operador, dan lugar a un múltiplo escalar de sí mismos. Este escalar λ recibe el nombre de autovalor.

El espacio de imágenes de caras a partir del cual obtener los autovectores se genera tomando un determinado número de imágenes (K) como *conjunto de diseño*.

De la misma forma que cualquier color puede generarse mediante la mezcla de los colores primarios, cualquier cara podría sintetizarse mediante una combinación de *eigenfaces*.



Las autocaras con las **componentes principales** (autovectores) de la matriz de covarianza de un conjunto de imágenes de caras. Caracterizan la variación global entre imágenes de caras.

Permiten **representar, de modo aproximado, la fisionomía** de cada individuo. Se trata de un subespacio de presentación **menos redundante** que el espacio original.

Ejemplo con las 4 autocaras principales (eigenfaces) de la base de datos

autocara nº1



autocara nº2



autocara nº3



autocara nº4




Ejemplo de un sistema de reconocimiento facial



Previo a la construcción del nuevo espacio de caras resulta conveniente reducir las diferencias debidas a luminosidad y a características externas a la cara \Rightarrow **normalización** de cada imagen para:

- (1) eliminar las características externas a la cara;
- (2) que la intensidad media de cada imagen sea 0

Para realizar (2), se determina la cara promedio y ésta se resta a todas las caras de la base de datos.



La aplicación de PCA sobre la matriz resultante del conjunto de K caras de diseño proporciona N autovalores relevantes \Rightarrow cada autovalor tiene asociado un autovector de la misma dimensión que las imágenes originales, es decir, cada autovector se puede representar como una imagen en el espacio de imágenes.

Ejemplo de un sistema de reconocimiento facial



Tras obtener el nuevo espacio generador de caras (de dimensión N), se realiza la proyección de cada cara sobre las *eigenfaces* obtenidas \Rightarrow para cada cara se obtiene un vector $\underline{\Omega}$ de longitud N .

Este vector se utiliza, junto con una medida de distancia, para determinar si la imagen que se presenta al sistema es una cara y, en caso afirmativo, decidir a qué individuo (de los utilizados en el conjunto de diseño) pertenece. Se aplicaría el “clasificador k -nn” sobre el espacio $\underline{\Omega}$.

Imagen a reconocer



Tres caras más parecidas



Imagen a reconocer



Tres caras más parecidas



Tal y como se ha presentado en estas transparencias, el sistema presenta muchas limitaciones.