

Tema 3: Segmentación

3.1. Introducción. Elementos y terminología

3.2. Segmentación de imágenes binarias

3.3. Segmentación de imágenes en escala de gris

3.4. Segmentación de imágenes en color

3.5. Técnicas basadas en aprendizaje estadístico. Aplicaciones

3.5. Técnicas basadas en aprendizaje estadístico



El **aprendizaje estadístico** permite abordar una tarea (clasificación/estimación/agrupamiento, entre otras) a partir de un conjunto de ejemplos suficientemente representativos de la tarea a resolver.

La segmentación se puede abordar como un proceso de clasificación/agrupamiento.



¿Qué tarea se puede abordar si se dispone de imágenes con frutas como las mostradas en la figura?

3.5. Técnicas basadas en aprendizaje estadístico



La solución pasa por modelar el problema desde un punto de vista analítico, diseñando una función matemática $g(\cdot)$ que permita resolver el problema de la mejor forma posible.

Son interesantes las técnicas **no paramétricas**. Es decir, aquéllas que para abordar el problema no asumen una forma concreta (lineal, cuadrática, ...) para $g(\cdot)$. Más bien, la función “más adecuada” se encuentra tras un proceso de **aprendizaje** con un **conjunto de ejemplos** representativos del problema a resolver, de modo que el modelo final está “dirigido por los datos” (*data-driven*). Es lo que se denomina *Machine Learning*, aprendizaje máquina o aprendizaje estadístico.



Machine learning is a subfield of computer science that evolved from the study of pattern recognition and computational learning theory in artificial intelligence.

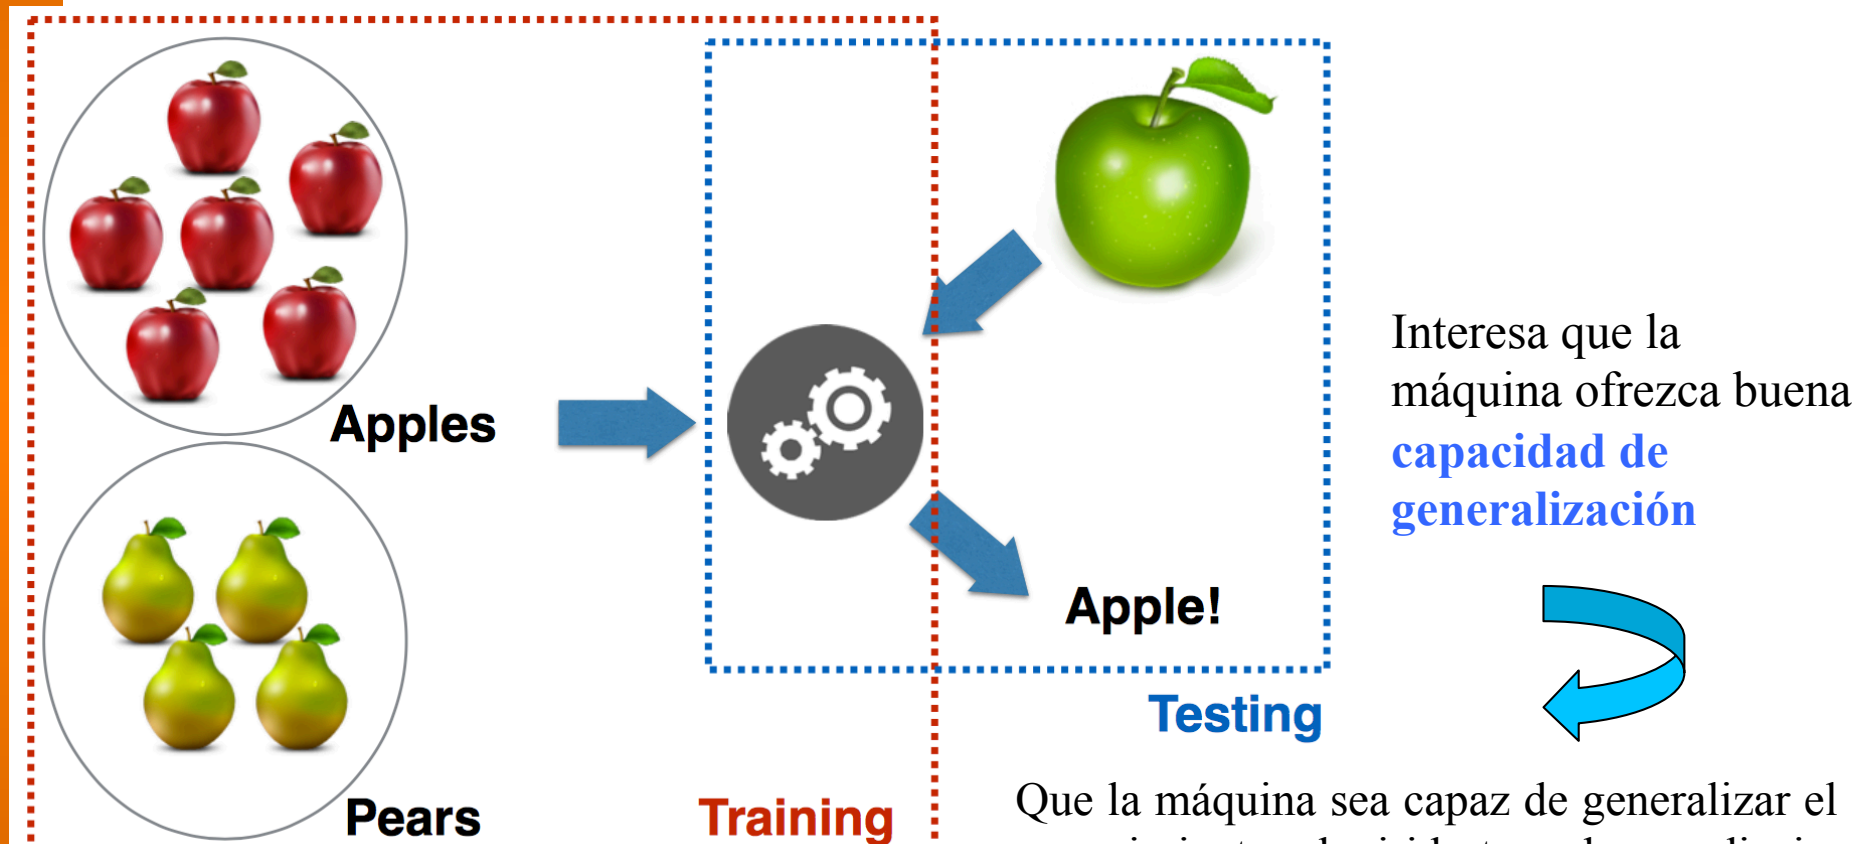
In 1959, Arthur Samuel defined machine learning as a "Field of study that gives computers the ability to learn without being explicitly programmed".

Machine learning explores the study and construction of algorithms that can learn from and make predictions on data. Such algorithms operate by building a model from example inputs in order to make data-driven predictions or decisions, rather than following strictly static program instructions.

3.5. Técnicas basadas en aprendizaje estadístico



Tarea de clasificación. Aprendizaje supervisado




El *training* se refiere al proceso de aprendizaje de la máquina (construcción del modelo).

Que la máquina sea capaz de generalizar el conocimiento adquirido tras el aprendizaje, proporcionando una respuesta correcta ante ejemplos no utilizados para diseñar el clasificador (conjunto de **entrenamiento** versus conjunto de **test**).

3.5. Técnicas basadas en aprendizaje estadístico



Tarea de agrupamiento (*clustering*). Aprendizaje no supervisado




También requiere una fase de aprendizaje (*training*).

3.5. Técnicas basadas en aprendizaje estadístico




OBJETIVO: Diferenciar peras de manzanas

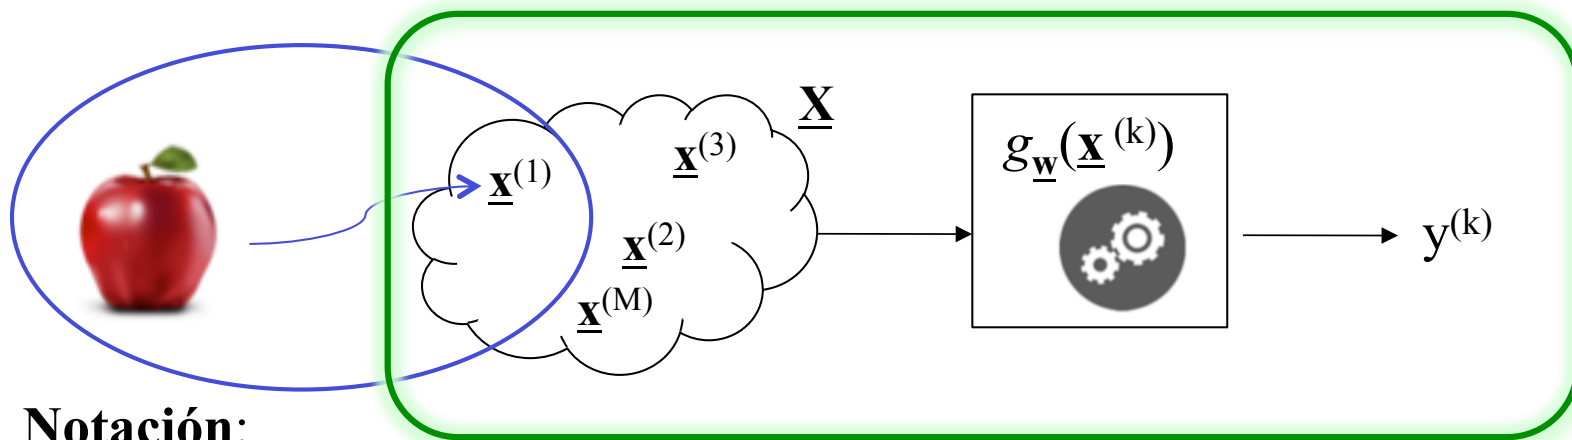


Las etiquetas sólo se utilizan en el aprendizaje supervisado.
El aprendizaje no supervisado no hace uso de etiquetas.



- **Muestras:** 
- **Características:** son descriptores de color, forma, textura, etc.
Las características a utilizar deben ser informativas para abordar el problema. De otro modo, es mejor no considerarlas.
- **Etiquetas:** pera (1), manzana (0)

3.5. Técnicas basadas en aprendizaje estadístico



Notación:

Disponemos de M ejemplos para diseñar la máquina (aprender el modelo – $g(\cdot)$).

$$\mathcal{X} = \{\underline{\mathbf{x}}^{(1)}, \underline{\mathbf{x}}^{(2)}, \dots, \underline{\mathbf{x}}^{(M)}\}$$

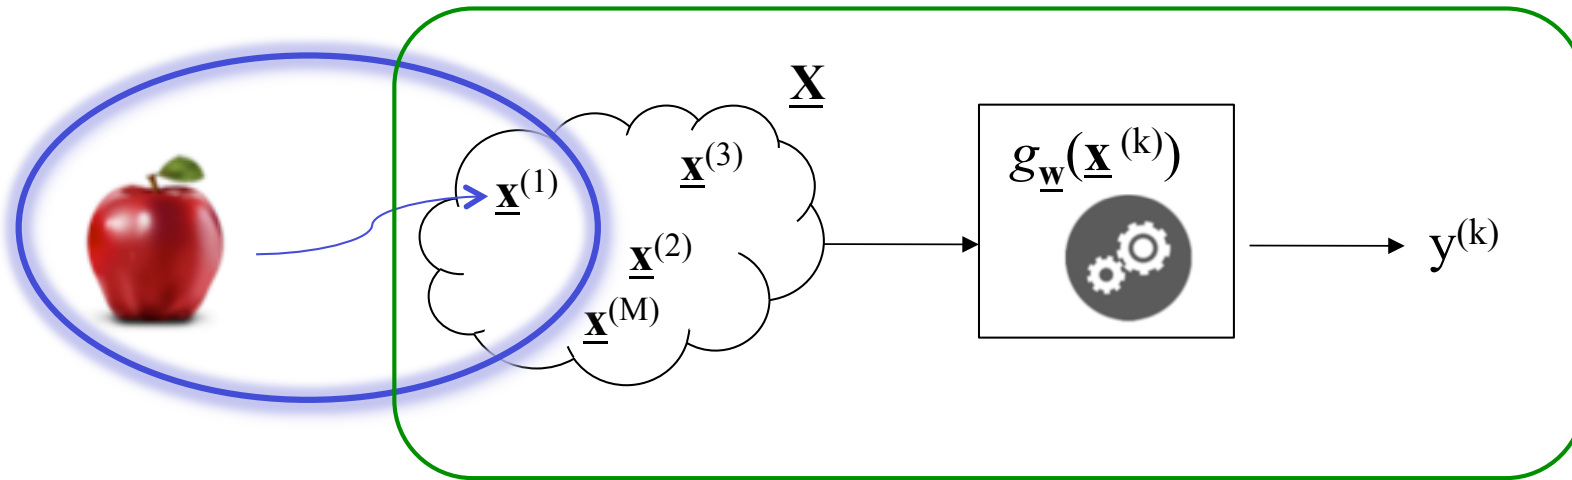
Cada ejemplo $\underline{\mathbf{x}}^{(k)}$ consta de N características (*features*) o variables:

$$\underline{\mathbf{x}}^{(k)} = (x^{(k)}_1, x^{(k)}_2, \dots, x^{(k)}_N) \longrightarrow \left\{ \begin{array}{l} x^{(k)}_1 : \text{característica 1} \\ x^{(k)}_2 : \text{característica 2} \\ \dots \\ x^{(k)}_N : \text{característica N} \end{array} \right.$$

N : dimensión del espacio de entrada a la máquina (sistema).

\mathcal{X} debe de estar formado por un conjunto de ejemplos suficientemente representativo del problema a tratar.

3.5. Técnicas basadas en aprendizaje estadístico



Extracción de características (*feature extraction*)

- **Objetivo de la extracción de características:** extraer información relevante para la tarea a resolver (segmentación).

- **Segmentación:** dividir la imagen en regiones con características similares.

Antes de segmentar es preciso definir qué se desea segmentar, de modo que se puedan extraer características informativas para realizar la segmentación.

La segmentación se puede abordar como una tarea de clasificación o de agrupamiento.

- **Clasificación:** utilizar el vector de características de un elemento y asignarlo a una de entre un conjunto finito de C clases (también denominadas categorías). El número C de categorías a discriminar es conocido.

3.5. Técnicas basadas en aprendizaje estadístico




Aprendizaje supervisado



Supervised learning: The computer is presented with example inputs and their desired outputs, given by a "teacher", and the goal is to learn a general rule that maps inputs to outputs.

- Conocemos el número de clases y la etiqueta de cada ejemplo.
- El diseño se realiza usando características y etiquetas.
- Ejemplo: k -nn, redes neuronales artificiales, ...
- Para la imagen de resonancia magnética del cerebro que se muestra a continuación,
 C_0 : materia gris; C_1 : materia blanca; C_2 : cráneo
 C_3 : fluido cerebro espinal; C_4 : fondo



3.5. Técnicas basadas en aprendizaje estadístico




Aprendizaje no supervisado



Unsupervised learning: No labels are given to the learning algorithm, leaving it on its own to find structure in its input. Unsupervised learning can be a goal in itself (discovering hidden patterns in data) or a means towards an end (feature learning).


- Agrupamiento (*clustering*). Objetivo: aprender la “estructura” de los datos agrupando los datos en grupos “consistentes”.
- Usando sólo las características, tratamos de buscar grupos en los datos.
- No utiliza etiquetas (en general no están disponibles) y a veces tampoco se conoce el número de grupos. En principio, cada grupo representa un “objeto” distinto.
- Ejemplo: algoritmo *k*-medias
(*k* es el número de grupos o *clusters*)
- Para un mismo conjunto de ejemplos, diferentes algoritmos de *clustering* conducen a diferentes *clusters*.



¿qué se representa
en cada eje?

Algoritmos de agrupamiento (I)

- Segmentación basada en **criterios de homogeneidad** en el espacio de características.
- Hay varias técnicas, algunas requieren conocer a priori cuántos grupos (*clusters*) se desea encontrar; otras intentan determinar el número de grupos (en base a criterios de homogeneidad).
- Típicamente son **algoritmos iterativos**; comienzan con una partición inicial en grupos/regiones en el espacio de características. Las regiones se modifican según un criterio de homogeneidad.




Ejemplo de algoritmo de agrupamiento con dos regiones (Ia)



Objetivo: dividir el espacio de características en base a la **mínima distancia** entre una observación/instancia/muestra/ejemplo y cada uno de los grupos. Se considera únicamente el representante de un grupo.

Ejemplo con un espacio de dos características



Ejemplo de algoritmo de agrupamiento con dos regiones (Ib)




Objetivo: dividir el espacio de características en base a la **mínima distancia** entre una observación/instancia/muestra/ejemplo y cada uno de los grupos. Se considera únicamente el representante de un grupo.

Cada *cluster* está representado por un centroide (en principio, el punto central – coordenadas obtenidas como el valor medio en cada característica).

Cada observación se asigna al *cluster* más próximo (criterio de similitud).

Ejemplo con un espacio de dos características y dos clusters



Algoritmo de agrupamiento k -medias (I)

En el algoritmo k -medias (o k -means), el parámetro k hace referencia al número de grupos (clusters). No se debe confundir con el parámetro k del clasificador k -nn.


Algoritmo k -means:

1. Inicialización. En general, sin información a priori, se eligen aleatoriamente k ejemplos (reales o no) como centros de los *clusters* (centroides),
 $k_j, j=1, 2, \dots, k$.

Nota: el resultado puede depender de los grupos iniciales.

Algoritmo de agrupamiento k -medias (II)

Ejemplo del algoritmo k -medias (k -means) con $k=3$



$k=3$ centroides: k_1 , k_2 , k_3

Algoritmo de agrupamiento k -medias (III)

En el algoritmo k -medias, el parámetro k hace referencia al número de grupos (clusters). No se debe confundir con el parámetro k del clasificador k -nn.


Algoritmo k -means:

1. Inicialización. En general, sin información a priori, se eligen aleatoriamente k ejemplos (reales o no) como centros de los *clusters* (centroides),
 $k_j, j=1, 2, \dots, k$.

Nota: el resultado puede depender de los grupos iniciales.

2. Asignar cada ejemplo al *cluster* del centroide más próximo (la medida de similitud puede ser la distancia).

Algoritmo de agrupamiento k -medias (IV)



Se asigna cada muestra al centroide más cercano.
Cada color representa un *cluster* distinto.

Algoritmo de agrupamiento k -medias (V)

En el algoritmo k -medias, el parámetro k hace referencia al número de grupos (clusters). No se debe confundir con el parámetro k del clasificador k -nn.


Algoritmo k -means:

1. Inicialización. En general, sin información a priori, se eligen aleatoriamente k ejemplos como centros de los *clusters* (centroides), $k_j, j=1, 2, \dots, k$.

Nota: el resultado puede depender de los grupos iniciales.

2. Asignar cada ejemplo al *cluster* al que corresponda el centroide más próximo.
3. Recalcular las posiciones de los centroides como el promedio de las observaciones asignadas a cada *cluster*.

Algoritmo de agrupamiento k -medias (VI)



Se recalcula la posición de cada centroide como el promedio de las muestras/observaciones/ejemplos de cada *cluster*.

Algoritmo de agrupamiento k -medias (VII)

En el algoritmo k -medias, el parámetro k hace referencia al número de grupos (clusters). No se debe confundir con el parámetro k del clasificador k -nn.

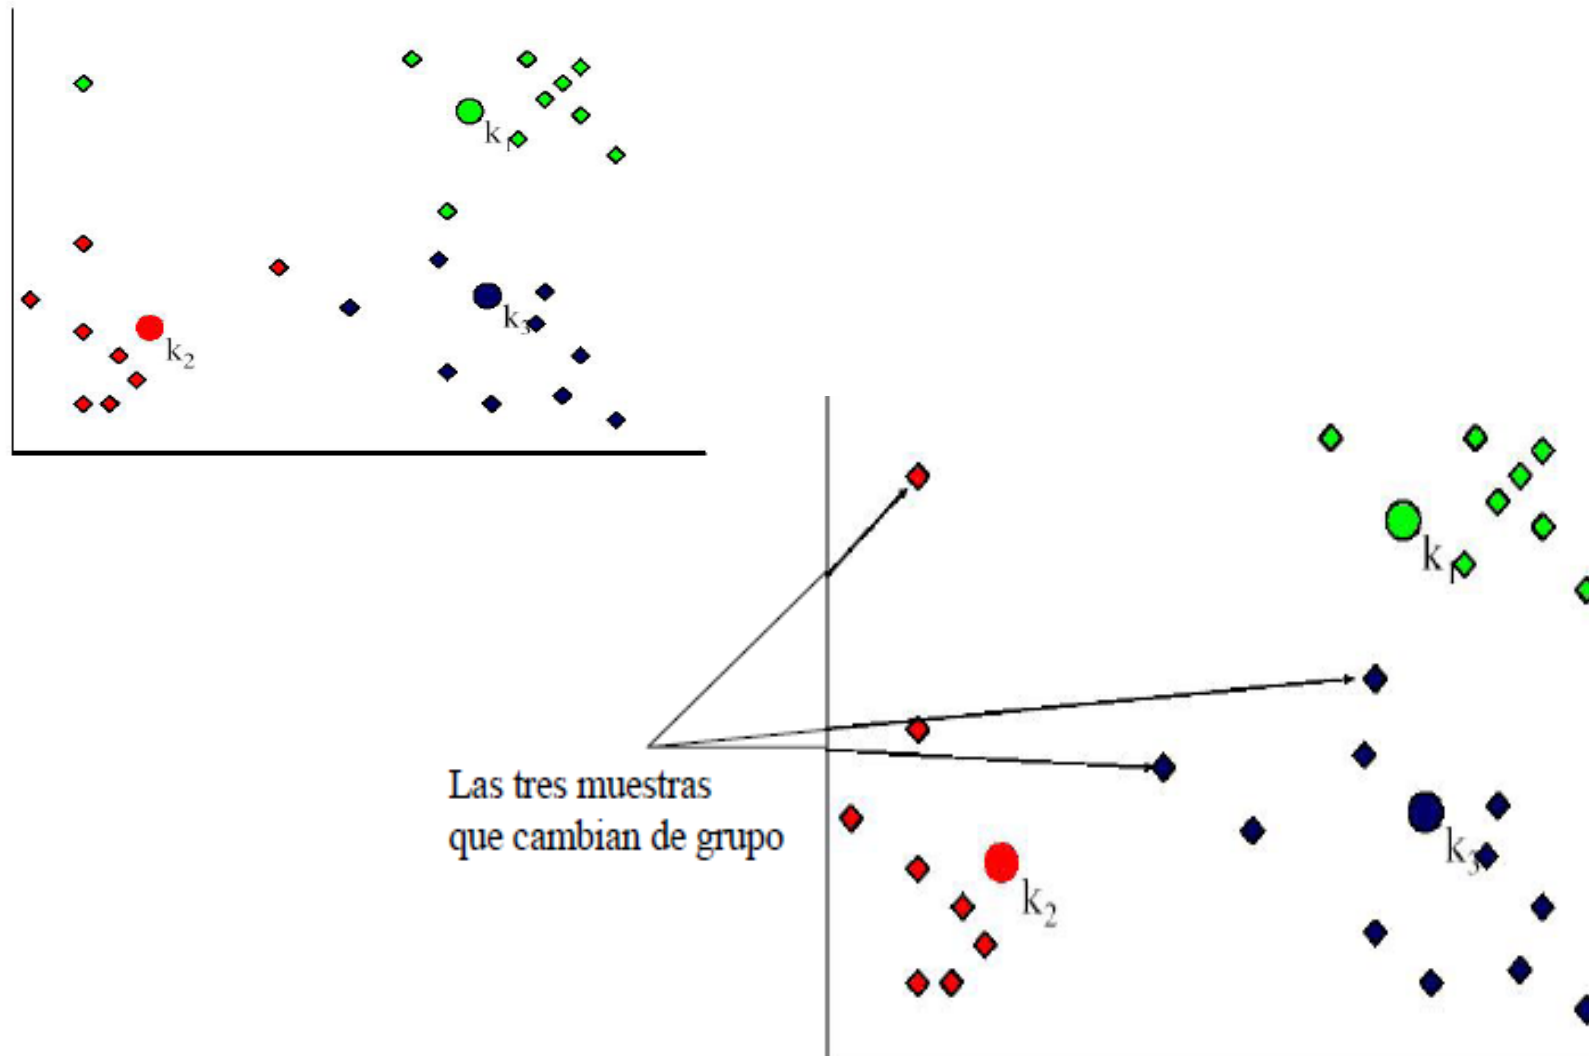
Algoritmo k -means:

1. Inicialización. En general, sin información a priori, se eligen aleatoriamente k ejemplos como centros de los *clusters* (centroides), $k_j, j=1, 2, \dots, k$.

Nota: el resultado puede depender de los grupos iniciales.

2. Asignar cada ejemplo al *cluster* al que corresponda el centroide más próximo.
3. Recalcular las posiciones de los centroides como el promedio de las observaciones asignadas a cada *cluster*.
4. Volver al paso 2 hasta que se cumpla el criterio de parada.
 - número máximo de iteraciones
 - estabilización en la posición de los centroides


Algoritmo de agrupamiento k -medias (VIII)



Se reasignan las muestras al centroide más cercano.

Algoritmo de agrupamiento k -medias (IX)

Recalcular los centros de los clusters



Reasignar las muestras al cluster más cercano ...

El criterio para detener el algoritmo puede ser un número máximo de iteraciones, la estabilización en la posición de los centroides, ...

Ejemplo de segmentación con k -medias (I)

Ejemplo: Segmentación basada en color utilizando el algoritmo k -medias (*clustering*).

H&E image




Image courtesy of Alan Partin, Johns Hopkins University

Imagen de tejido coloreada con hemotoxylina (H) y eosina (E). El coloreado ayuda a los especialistas a distinguir diferentes tipos de tejidos.

Ejemplo tomado de <http://es.mathworks.com/solutions/machine-learning/examples.html?file=/products/demos/machine-learning/color-based-segmentation-using-k-means-clustering/color-based-segmentation-using-k-means-clustering.html>

Ejemplo de segmentación con k -medias (II)



Objetivo: segmentar las zonas de diferentes colores de forma automática.

A grandes rasgos (ignorando variaciones de luminosidad), se distinguen tres colores: blanco, azul y rosa $\Rightarrow k$?

Primero, se determinan las características a considerar.

H&E image




Image courtesy of Alan Partin, Johns Hopkins University


Como la información está en los colores, se realiza la conversión del espacio RGB al LAB y se consideran las componentes de color a y b .

A continuación, sobre el espacio ab se aplica el esquema k -medias con $k=3$.

Ejemplo de segmentación con k -medias (III)




image labeled by cluster index




Capa de etiquetas

objects in cluster 1



objects in cluster 2



objects in cluster 3

